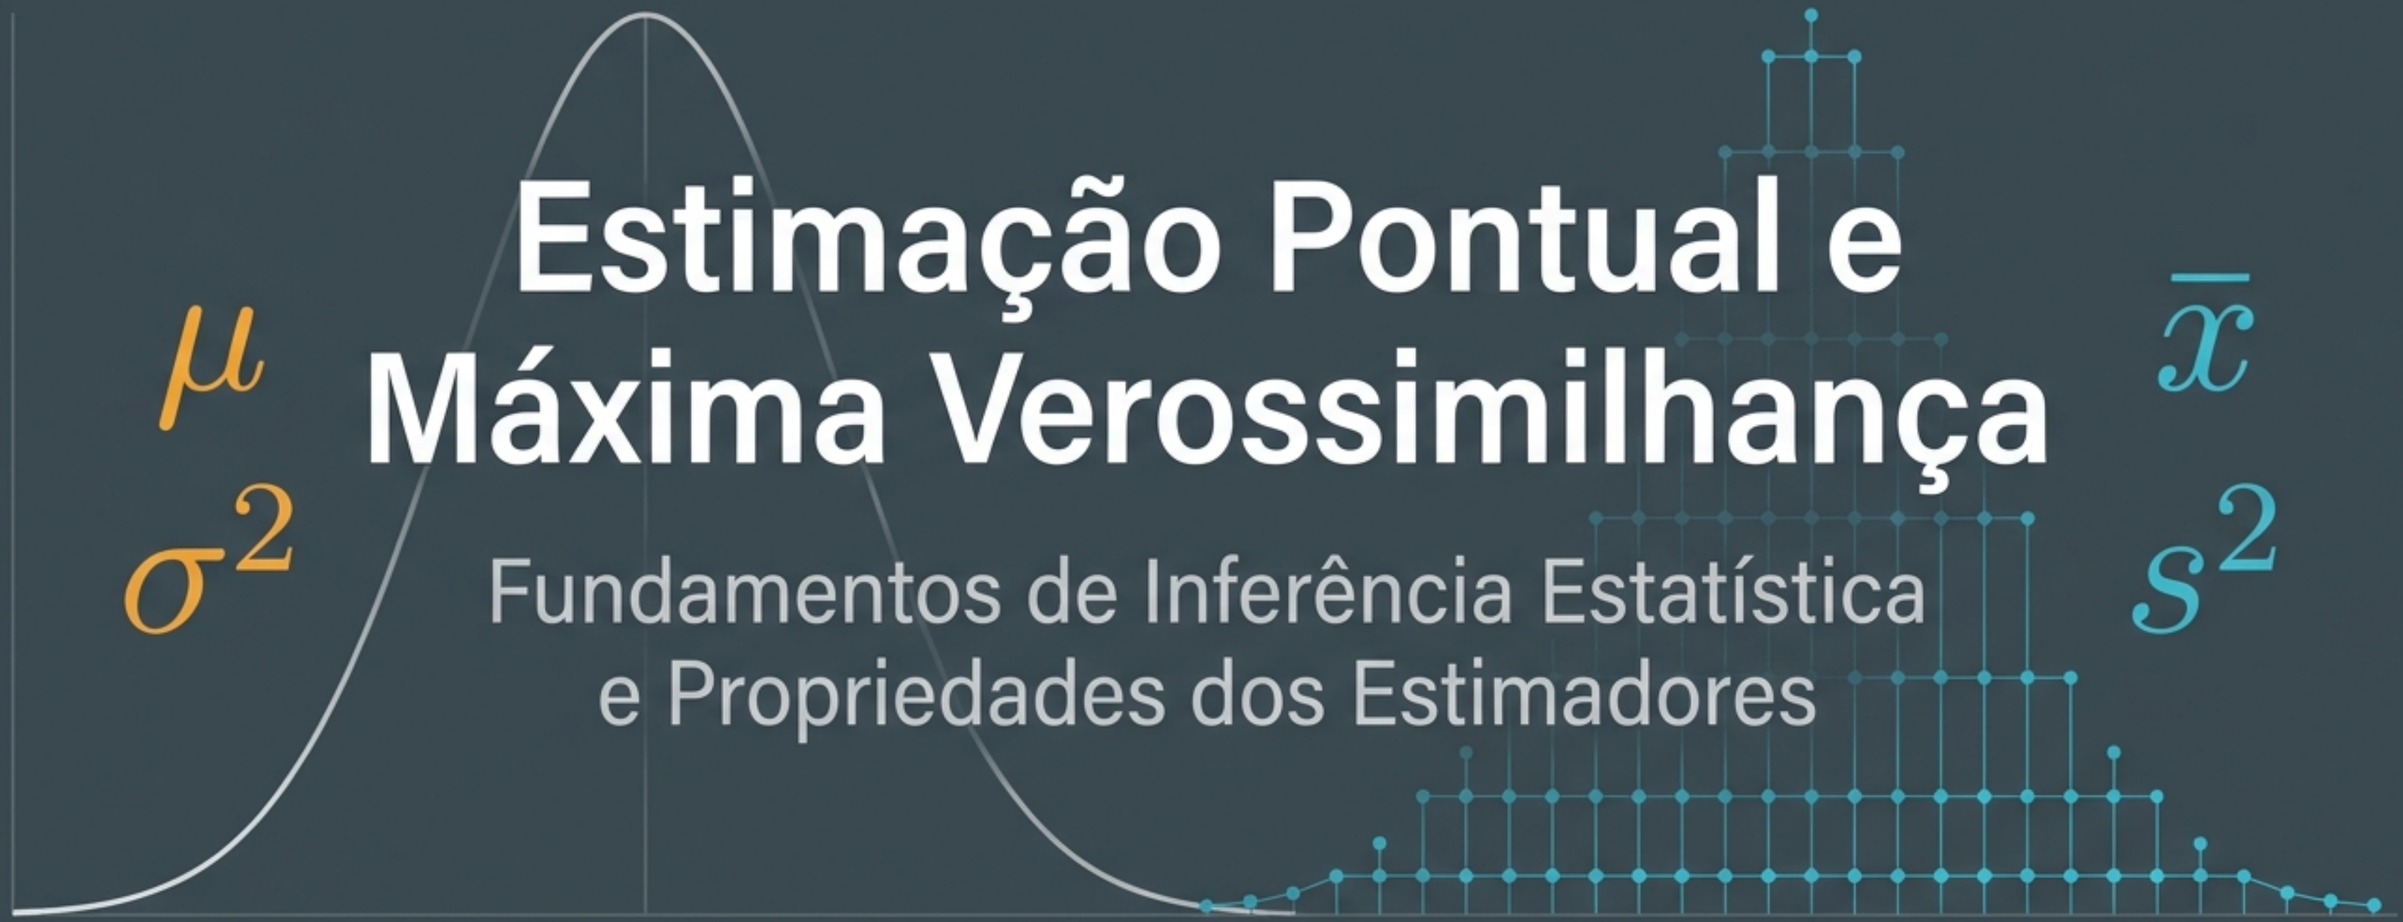


Estimação Pontual e Máxima Verossimilhança

Fundamentos de Inferência Estatística e Propriedades dos Estimadores

μ

σ^2

$\bar{x}$

s^2

Gemini Notebook

O Paradigma da Inferência: Onde Moram os Parâmetros?



O objetivo da inferência é usar as ferramentas da amostra para descobrir a verdade da população. O “chapéu” (^) indica que o valor é uma estimativa.

Gemini Notebook

O Motor da Estimação: O Algoritmo de Máxima Verossimilhança (MV)

1

Definir $L(\theta)$

$\prod f(\theta)$

Escrever a Função de Verossimilhança (Produtório de densidades/massas).

2

Aplicar $\ln()$

$\ln()$

Transformar o produtório em somatório criando a Log-Verossimilhança $l(\theta)$. O "truque" matemático.

3

Derivar

$\frac{\partial}{\partial \theta} f(\theta)$

Calcular a derivada parcial de $l(\theta)$ em relação ao parâmetro de interesse.

4

Igualar a Zero

$\theta \rightarrow \hat{\theta}$

Encontrar o ponto crítico. Neste momento, o parâmetro θ ganha o chapéu $\hat{\theta}$.

5

Checar Derivada 2ª

$[\nabla^2 \checkmark]$

Garantir que a matriz Hessiana é negativa definida (confirmação de máximo global).

Gemini Notebook

A Função Objetivo: O Modelo Normal

$$L(\mu, \sigma^2) = \prod_{i=1}^{n} \left[\frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{1}{2\sigma^2}(X_i - \mu)^2 \right) \right]$$

A Constante
Termos que não dependem do índice i.

A Exponencial
Contém o núcleo da distância entre a amostra e a média.

⚠ O Pesadelo da Derivação
Derivar diretamente exigiria a regra do produto para n termos complexos.

Necessitamos de uma transformação monotônica que simplifique o cálculo sem alterar o ponto de máximo.

Gemini Notebook

O "Truque" do Logaritmo: Simplificando a Otimização

$$L(\mu, \sigma^2) = (2\pi\sigma^2)^{-n/2} \exp\left(-\frac{1}{2\sigma^2}\sum(X_i - \mu)^2\right)$$

O "exp" é cancelado (A)

Aplicando ln()

Produtório vira Somatório (B)

$$l(\mu, \sigma^2) = -\frac{n}{2}\ln(2\pi\sigma^2) - \frac{1}{2\sigma^2}\sum(X_i - \mu)^2$$

A função log é estritamente crescente. Maximizar $l(\theta)$ é matematicamente equivalente a maximizar $L(\theta)$, mas computacionalmente trivial.

Gemini Notebook

Os Estimadores Finais da Normal

Média Populacional (μ)

$$\hat{\mu} = \bar{X} = \frac{\sum X_i}{n}$$

A média amostral é o estimador natural.

Variância Populacional (σ^2)

$$\hat{\sigma}^2 = \frac{\sum (X_i - \bar{X})^2}{n}$$

A variância amostral (com denominador n).

⚠ Assumindo Matriz Hessiana Negativa Definida (ponto de máximo garantido).

Gemini Notebook

Aplicação Rápida: O Modelo Poisson

1. Verossimilhança

$$L(\lambda) = \frac{e^{-n\lambda}\lambda^{\sum X_i}}{\prod X_i!}$$

2. Log + Derivada = 0

$$\frac{d}{d\lambda} l(\lambda) = -n + \frac{\sum X_i}{\lambda} = 0$$

3. O Resultado Final

Colocando o ‘chapéu’...

$$\hat{\lambda} = \frac{\sum X_i}{n} = \bar{X}$$

Assim como na Normal, a média amostral ($\bar{X}$) é o estimador de máxima verossimilhança para a média populacional (λ) na Poisson.

Gemini Notebook

A Propriedade da Invariância



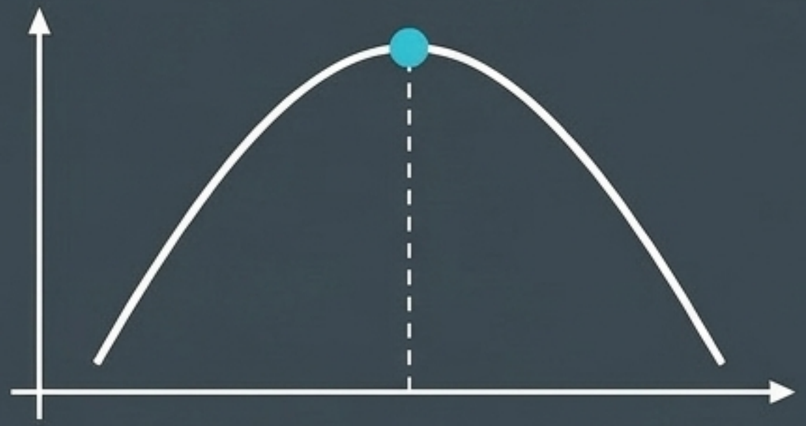
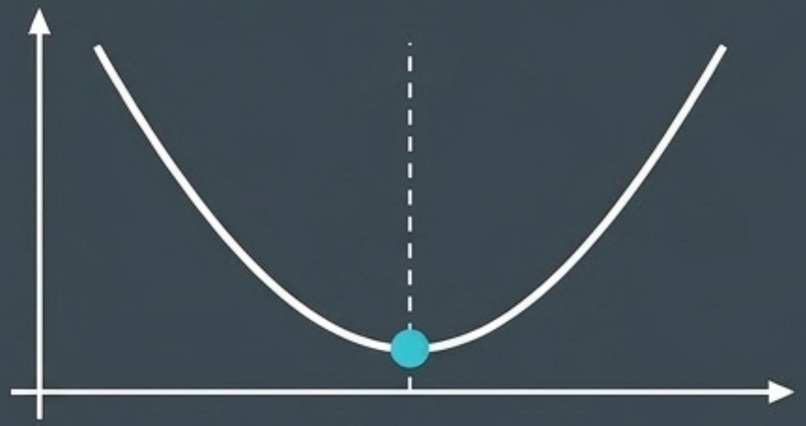
Exemplo de Aplicação (Poisson)

- Queremos estimar a probabilidade de zero ocorrências: P(X=0) = $e^{-\lambda}$
- Sabemos que o estimador de λ é $\hat{\lambda} = \bar{X}$
- **Pela invariância, o estimador MV de $e^{-\lambda}$ é simplesmente $e^{-\bar{X}}$.**

Não precisamos recalcular a derivada para funções do parâmetro original.

Gemini Notebook

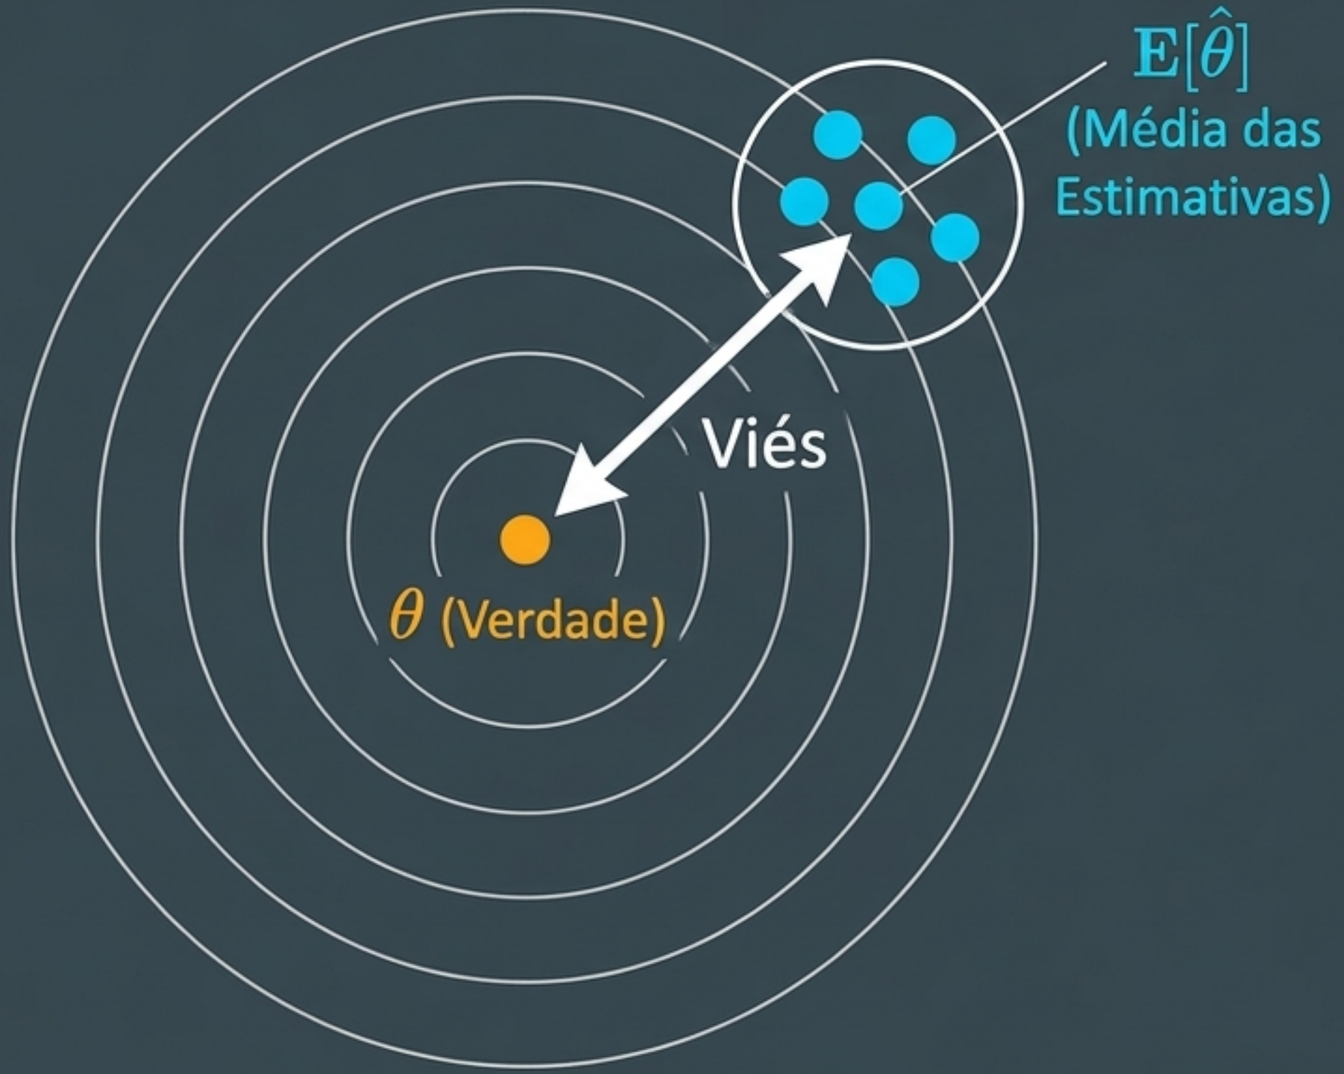
Sob o Capô do Machine Learning

Estatística Clássica	Machine Learning
	
• **Objetivo**: Encontrar os verdadeiros parâmetros da distribuição. • **Método**: Maximizar a função de Log-Verossimilhança.	• **Objetivo**: Encontrar os pesos que melhor ajustam as predições (ex: Mínimos Quadrados). • **Método**: Minimizar a Função de Custo / Perda (Loss Function).

Otimizar a Verossimilhança e Minimizar o Erro Quadrático são fundamentalmente o mesmo processo algorítmico de otimização matemática, apenas com funções objetivo invertidas.

Gemini Notebook

Avaliando a Qualidade: Propriedade 1 - O Viés (Bias)



$$B(\hat{\theta}) = \mathbf{E}[\hat{\theta}] - \theta$$

Não Viesado (Unbiased)

Se $\mathbf{E}[\hat{\theta}] = \theta$. O viés é zero. Em média, o estimador acerta a mosca.

Viesado (Biased)

O estimador sistematicamente erra o alvo, subestimando ou superestimando o parâmetro, mesmo em média.

Gemini Notebook

Propriedade 2: Erro Quadrático Médio (EQM)

$$EQM = \mathbf{E}\left[(\hat{\theta} - \theta)^2\right]$$

$$EQM = \mathbf{E}\left[\hat{\theta}^2\right] - 2\theta\,\mathbf{E}[\hat{\theta}] + \theta^2$$

$$\boxed{EQM = \text{Variância}(\hat{\theta}) + \left[\,\text{Viés}(\hat{\theta})\,\right]^2}$$

Conexão Direta com Machine Learning:

Em Aprendizado de Máquina, esta equação exata governa o famoso Balanço ViésVariância (Bias-Variance Tradeoff). Para minimizar o erro total, modelos complexos reduzem o viés ao custo de aumentar a variância, e vice-versa.

Gemini Notebook

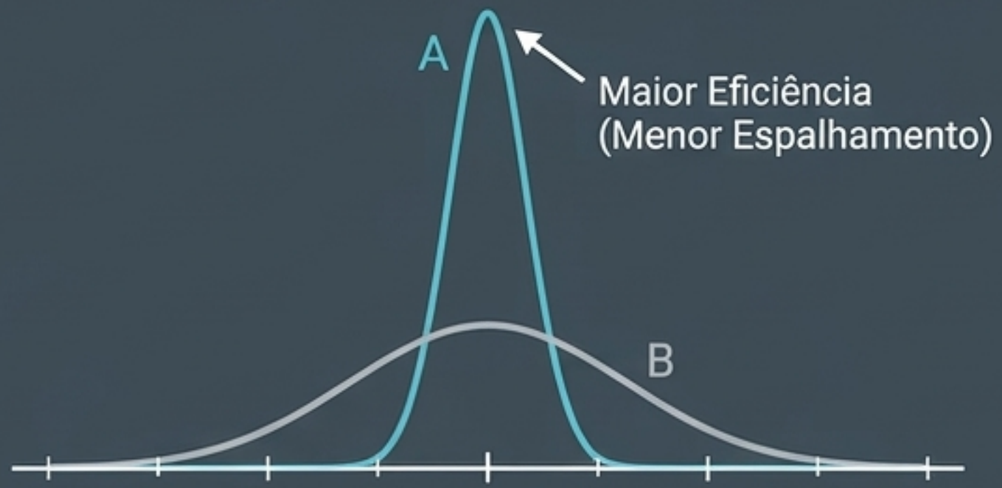
Propriedades 3 e 4: Eficiência e Consistência

Eficiência

Comparando dois estimadores não viesados ($\hat{\theta}_1$ e $\hat{\theta}_2$).

O mais eficiente possui a menor variância:

$$\mathrm{Var}(\hat{\theta}_1) < \mathrm{Var}(\hat{\theta}_2).$$



Consistência (Comportamento Assintótico)

O que acontece quando o tamanho da amostra $n \to \infty$?

O que acontece quando o tamanho da amostra $n \to \theta$.

Um estimador é consistente se:

$$\mathrm{E}[\hat{\theta}] \to \theta \quad \text{e} \quad \mathrm{Var}(\hat{\theta}) \to 0.$$

Validado por limites probabilísticos (ex: Desigualdade de Tchebychev).
O erro quadrático médio colapsa a zero.

Gemini Notebook

O Paradoxo da Variância Amostral

O estimador de Máxima Verossimilhança para a variância ($\hat{\sigma}^2$) é VIESADO.

$$E[\hat{\sigma}^2] = \left[\frac{n-1}{n}\right] * \sigma^2$$

⚠ **Interpretação:**

Como a fração (n-1)/n é estritamente menor que 1, o estimador MV sistematicamente subestima a verdadeira variância da população. Ele é matematicamente "puxado" para perto demais da média amostral.

Gemini Notebook

A Correção de Bessel: O Porquê do 'n-1'

O Fator de Correção

Multiplicamos o estimador original pelo inverso do seu viés matemático: n / (n-1).

A Matemática do Cancelamento

$$E\left[\frac{n}{n-1}\hat{\sigma}^2\right] = \frac{\cancel{n}}{\cancel{n-1}}\left(\frac{\cancel{n-1}}{\cancel{n}}\right)\sigma^2 = \sigma^2$$

O Novo Estimador Não Viesado

Cria-se o estimador não viesado S^2 (o padrão em todos os pacotes de software estatístico).

$$S^2 = \frac{\sum_{i=1}^{n}(X_i - \overline{X})^2}{n-1}$$

Gemini Notebook

Cheat Sheet: Tabela de Estimadores MV

Distribuição	Parâmetro (θ)	Estimador MV ($\hat{\theta}$)	É Viesado?
Normal	μ (Média)	$\bar{X}$	Não
Normal	σ^2 (Variância)	$\frac{\sum(X_i - \bar{X})^2}{n}$	Sim (Usa-se S^2 para corrigir)
Poisson	λ (Taxa/Média)	$\bar{X}$	Não
Bernoulli / Binomial	p (Probabilidade)	$\bar{X}/m$ (ou $\hat{p}$)	Não

A escolha do estimador ideal depende de um balanço delicado entre viés, variância e complexidade computacional.

Gemini Notebook