

EST5507 • Modelos de Regressão

Análise de Diagnóstico e Modelos Lineares Generalizados (MLG)

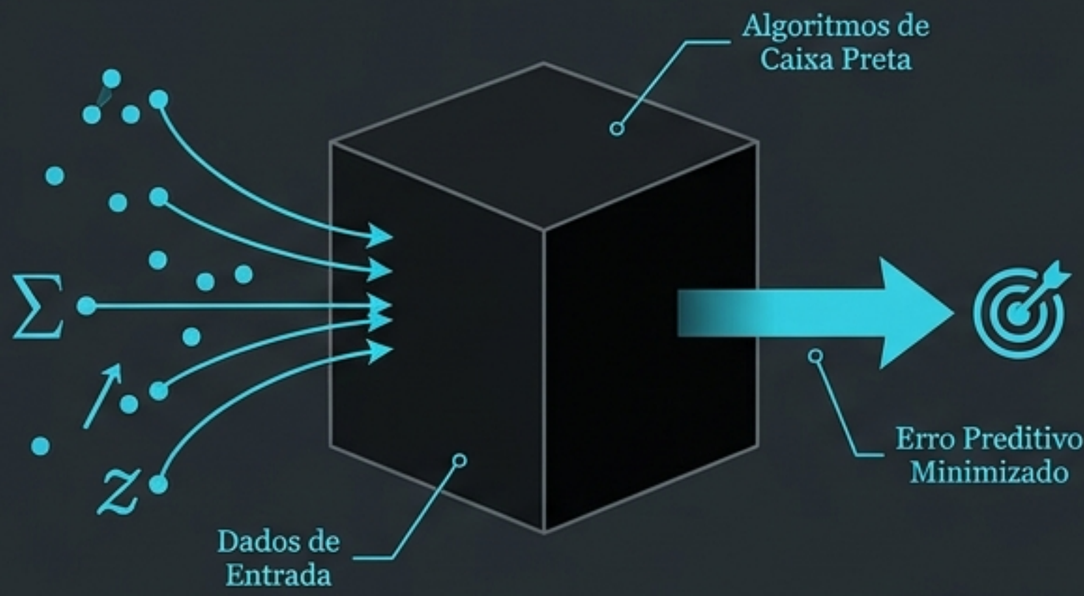
Da validação de premissas clássicas à extensão para a Família Exponencial.

Material de Referência Pós-Graduação • Prof. Cibele Russo

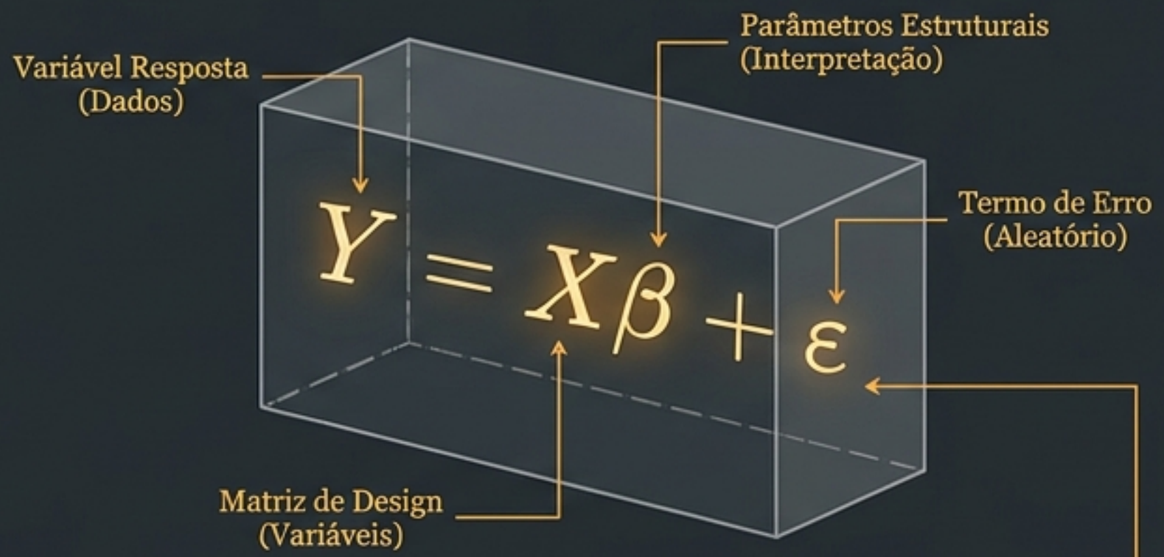
Gemini Notebook

O Paradigma da Modelagem Estatística

Predição Pura (Machine Learning)



Inferência (Modelagem Estatística)



Ao contrário de algoritmos de aprendizado de máquina focados apenas no erro preditivo, a modelagem estatística exige a interpretação válida dos parâmetros (β).

O Papel do Diagnóstico

Para que a interpretação seja válida, as suposições matemáticas devem espelhar a realidade dos dados. O ajuste inicial não garante a validade inferencial.

O R^2 nos diz o quão bem a reta se ajusta, não se a reta é o modelo certo para os dados.

Gemini Notebook

A Anatomia do Modelo Linear Clássico

Vetor de Respostas (Contínuas).

$$Y = X\beta + \varepsilon$$

Componente Sistemático (Preditor Linear).

Vetor de Erros Aleatórios.

1. Média Zero

$$E(\varepsilon) = 0$$

2. Variância Constante e Independência

$$Var(\varepsilon) = \sigma^2 I$$

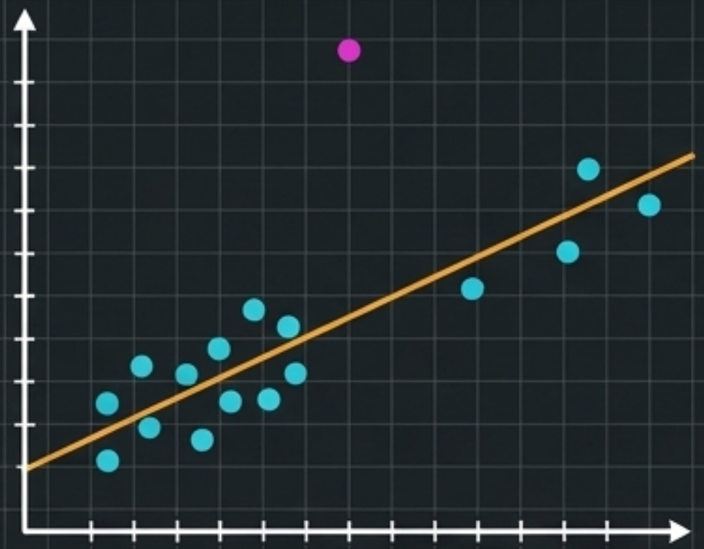
Homocedasticidade e Erros Não-Correlacionados.

3. Distribuição

Sob a imposição de Normalidade, a independência estrita é garantida e o estimador de Mínimos Quadrados coincide com o de Máxima Verossimilhança.

Gemini Notebook

A Tipologia das Anomalias

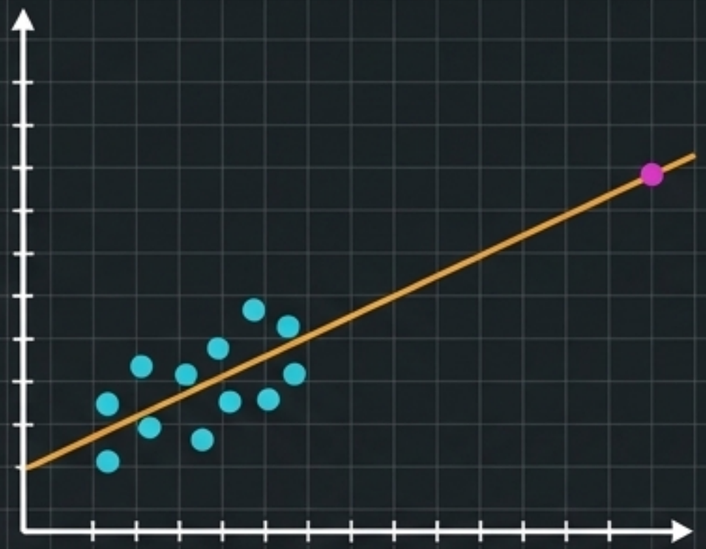


Ponto Aberrante (Outlier)

Distante da massa no eixo da resposta (Y).

Sintoma: Alto resíduo.

Impacto: Aumenta a variância estimada; pode não deslocar a reta se a alavanca for baixa.

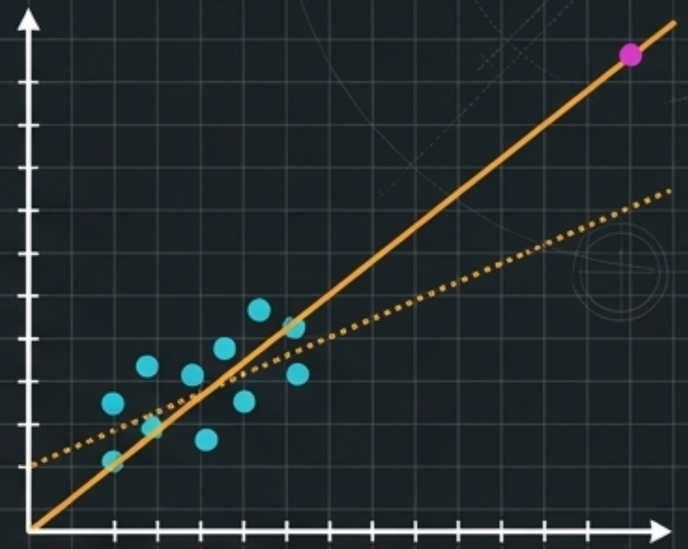


Ponto de Alavanca (Leverage)

Distante da massa no espaço das covariáveis (X).

Sintoma: Elevado h_{ii} na Matriz Chapéu.

Impacto: Alto potencial de atrair a reta, mas não altera a inclinação se estiver alinhado com a tendência.



Ponto Influente

Alavanca elevada combinada com afastamento no eixo Y.

Impacto (Crítico): Muda a inferência. Altera ativamente as estimativas dos parâmetros (β).

Gemini Notebook

A Matemática do Diagnóstico I: Alavanca e Resíduos

Medindo a Alavanca (Espaço X)

$$H = X(X^T X)^{-1} X^T$$

A projeção de Y ocorre via Matriz Chapéu.

A alavanca da i-ésima observação é o elemento da diagonal h_{ii}.

⚠ Alerta para $h_{ii} > 2p/n$

Medindo Aberrações (Espaço Y)

O resíduo ordinário $e_i = y_i - \hat{y}_i$ sofre interferência da própria alavanca. A solução é padronizar.

$$t_i = \frac{e_i}{\sigma_{(i)}\sqrt{1 - h_{ii}}}$$

Resíduo Estudentizado Externo (Jackknife)

Excluir a observação i no cálculo da variância previne que um outlier mascare seu próprio desvio.

Gemini Notebook

A Matemática do Diagnóstico II: Medidas de Influência

Distância de Cook (D_i)

Mede a alteração vetorial global nos parâmetros quando o caso *i* é removido (Case Deletion/Influência Global).

$$D_i = \frac{(\beta_{(i)} - \beta)^T (X^T X) (\beta_{(i)} - \beta)}{p\sigma^2}$$

Funcionalmente, combina o quadrado do resíduo com o fator de alavancagem:

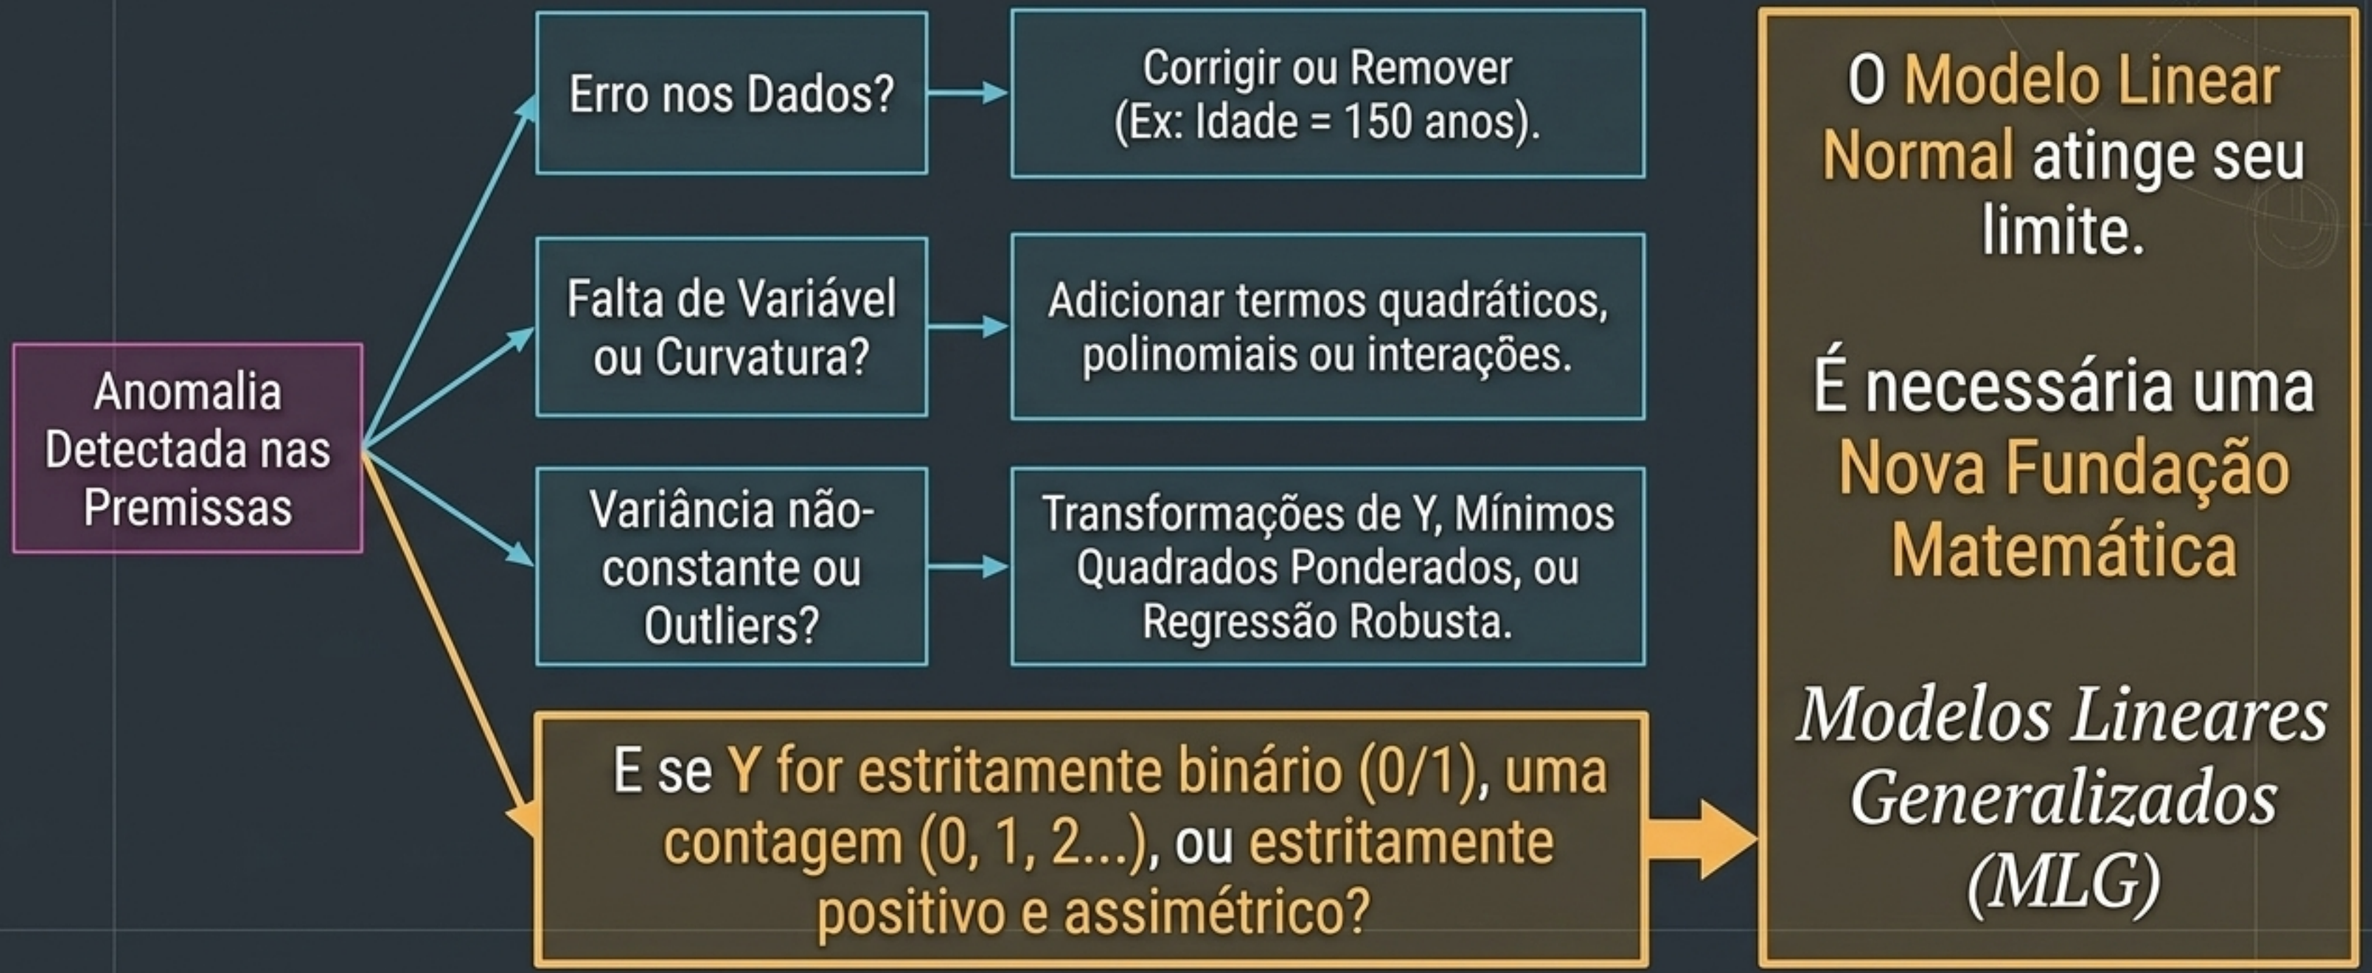
$$\propto (t_i^2) \cdot \frac{h_{ii}}{1-h_{ii}}$$

Outras Métricas da Análise Confirmatória

- **DFFITS / DFBETAS**: Impacto sobre o valor ajustado e parâmetros individuais.
- **Influência Local** (Cook, 1986): Perturbações diretas na verossimilhança sem necessidade de exclusão de dados.

Gemini Notebook

Fluxograma de Intervenção: Esgotando o Linear Clássico

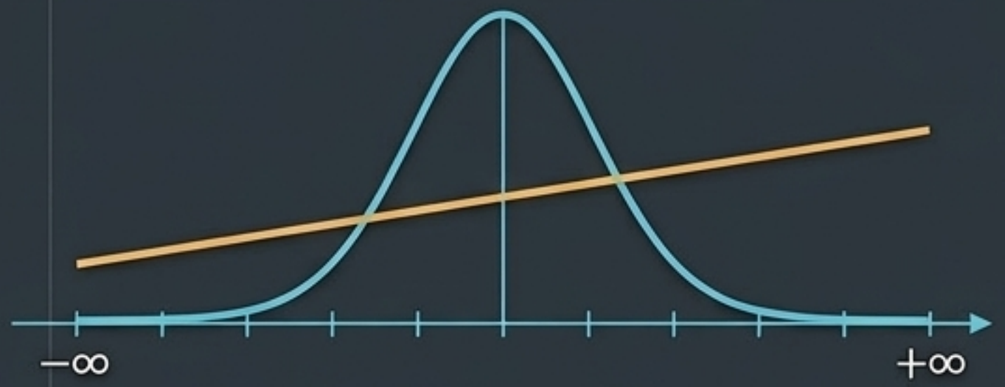


Gemini Notebook

O Salto para a Generalização (Nelder & Wedderburn)

O Problema

Modelo Linear Clássico



O Modelo Linear exige normalidade e permite que Y assuma qualquer valor em $(-\infty, \infty)$.

Falha gravemente para **proporções**, **contagens** ou **tempos de falha**.

A Solução

Modelos Lineares Generalizados (MLG)



Flexibiliza a distribuição da variável resposta Y além da Normal.

Preserva a tratabilidade e a **interpretabilidade** do componente linear $X\beta$.

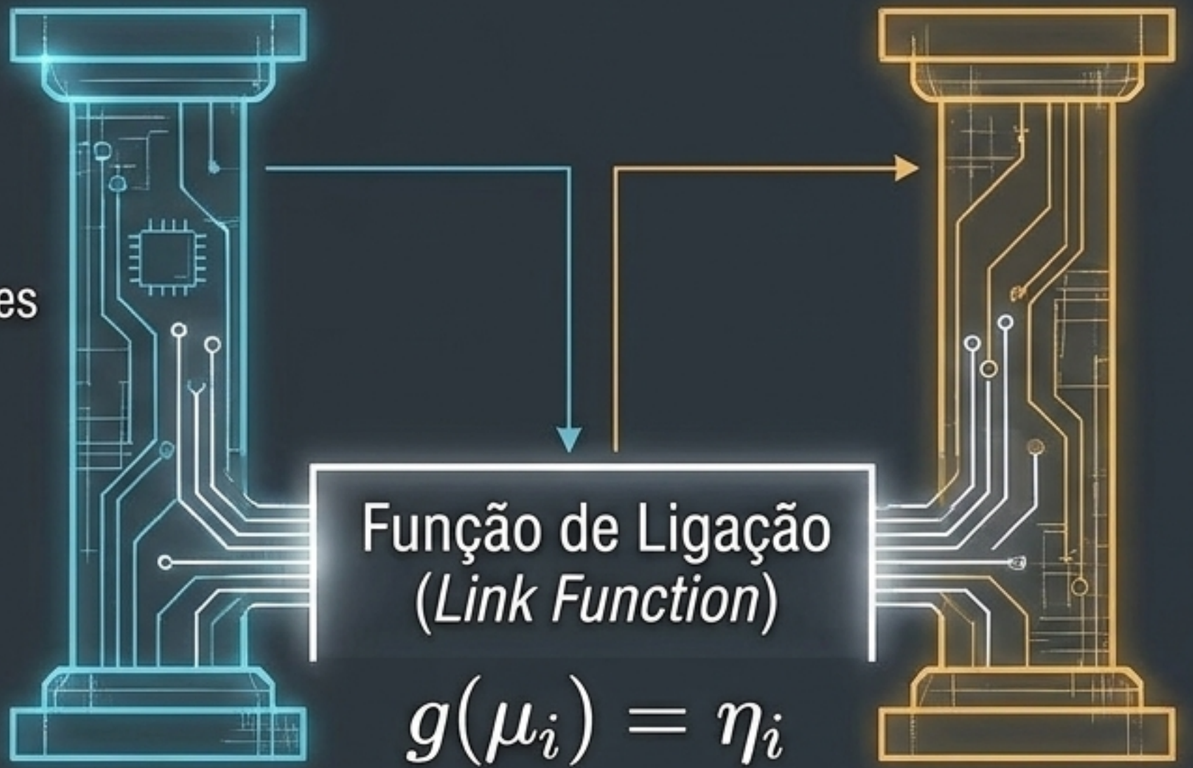
Exige estimação iterativa, não podendo ser resolvido por álgebra linear simples.

Gemini Notebook

A Anatomia de um MLG

Componente Aleatório

- Variáveis Y_i independentes com distribuição pertencente à Família Exponencial.
- Define a média μ_i e a estrutura de variância.



Componente Sistemático

Preditor linear:

$$\eta_i = X_i^T \beta.$$

Onde as covariáveis e parâmetros interpretáveis entram.

Uma função monótona e diferenciável.
Liga a média da distribuição ao preditor linear, garantindo que o modelo produza apenas valores válidos no espaço amostral de Y.

Gemini Notebook

O Coração do MLG: A Família Exponencial

Parâmetro Canônico
(diretamente ligado à média).

Função geradora de
média e variância.

$$f(y_i; \theta_i, \varphi) = \exp\left\{ \frac{y_i\theta_i - b(\theta_i)}{\varphi} + c(y_i, \varphi) \right\}$$

Parâmetro Canônico
(diretamente ligado à média).

Parâmetro de Dispersão
(controla variabilidade extra).

Termo de normalização
independente de θ_i.

Nota: Formulações alternativas existem na literatura (ex: Gilberto Paula vs. Gaus, Clarice Demétrio, Rafael Moral), mas culminam nas mesmas propriedades distributivas.

Gemini Notebook

Propriedades Fatoriais da Família Exponencial

Do Mapeamento de $b(\theta_i)$ derivamos o comportamento do modelo

$$b(\theta_i)$$

A Média

$$E(Y_i) = \mu_i = b'(\theta_i)$$

Média — Primeira Derivada

A primeira derivada em relação ao parâmetro canônico gera o valor esperado.

A Variância

$$Var(Y_i) = \varphi \cdot b''(\theta_i)$$

Variância — Parâmetro de Dispersão — Segunda Derivada

A Função de Variância V(μ):

Nos MLGs, a variância não é mais uma constante $\sigma^2\mathbf{I}$. Ela é moldada pela segunda derivada e geralmente depende ativamente da média:

$$Var(Y) = \varphi \cdot V(\mu).$$

Quebra definitiva da homocedasticidade clássica.

Gemini Notebook

O Panteão das Ligações Canônicas

A ligação canônica ocorre de forma elegante quando $\theta_i = \eta_i$.

Distribuição	Função de Variância $V(\mu)$	Ligação Canônica
Normal	$V(\mu) = 1$	Identidade ($\eta = \mu$)
Poisson (Contagem)	$V(\mu) = \mu$	Logarítmica ($\eta = \log \mu$)
Binomial (Proporção)	$V(\mu) = \mu(1 - \mu)$	Logito ($\eta = \log\left(\frac{\mu}{1-\mu}\right)$)
Gama (Assimetria Positiva)	$V(\mu) = \mu^2$	Recíproca ($\eta = \mu^{-1}$)
Inversa Normal	$V(\mu) = \mu^3$	Recíproca Quadrática ($\eta = \mu^{-2}$)

Gemini Notebook

Síntese Estrutural & Próximos Passos

Principais Insights:

1. **Diagnóstico é Geometria e Validação:**
   Anomalias (Alavanca e Influência) ditam parâmetros. Ignorá-las invalida qualquer interpretação inferencial causal, mesmo com alto R^2.
2. **Influência Exige Intervenção:**
   A matemática de Cook quantifica a fragilidade do modelo e aponta onde o paradigma linear clássico precisa ser revisto.
3. **A Generalização Salva a Estrutura:**
   A Família Exponencial, via Função de Ligação, expande os horizontes da modelagem para lidar com a realidade dos dados sem perder o rigor analítico.



Teaser (Próxima Aula):

Como avaliar o diagnóstico dentro deste novo paradigma?

Entra a Função Desvio (Deviance) e a análise específica via Resíduos do Desvio nos Modelos Lineares Generalizados.

Gemini Notebook