EST5507 - Modelos de Regressão

Modelo Linear com Matriz de Planejamento de Posto Incompleto

Diagnóstico, Consequências Matemáticas e Soluções Pragmáticas

Profª. Cibele Russo

Gemini Notebook

Cronograma e Próximos Passos



28/10	30/10	03/11 & 06/11	20/11	27/11
Sem Aula	**Entrega do Tema**	**Sem Aula**	**Sem Aula**	**Prova**
Dia do Funcionário Público	Resumo de Congresso / Proposta de Dados	Eventos em São Carlos e Vitória	Feriado - Consciência Negra	Avaliação Teórica e Prática

Próximo Tópico (Sexta-feira): Introdução aos Modelos Lineares Generalizados (MLGs) — Foco em aplicações e métodos iterativos.

Gemini Notebook

O Contraste de Mundos na Matriz X

Mundo Ideal: Posto Completo

- **Dimensão:** Matriz $\mathbf{X}$ $(n \times p)$
- **Posto:** Máximo $(r = p)$
- **Diagnóstico Numérico:** $|\mathbf{X}^\top\mathbf{X}| \neq 0$
- **Conclusão:** Solução única para $\hat{\boldsymbol{\beta}}$

O Problema: Posto Incompleto

- **Dimensão:** Matriz $\mathbf{X}$ $(n \times p)$
- **Posto:** Incompleto $(r < p)$
- **Condição:** Dependência linear exata nas colunas
- **Diagnóstico Numérico:** $|\mathbf{X}^\top\mathbf{X}| = 0$
- **Conclusão Matemática:** A inversa usual $(\mathbf{X}^\top\mathbf{X})^{-1}$ NÃO existe

Gemini Notebook

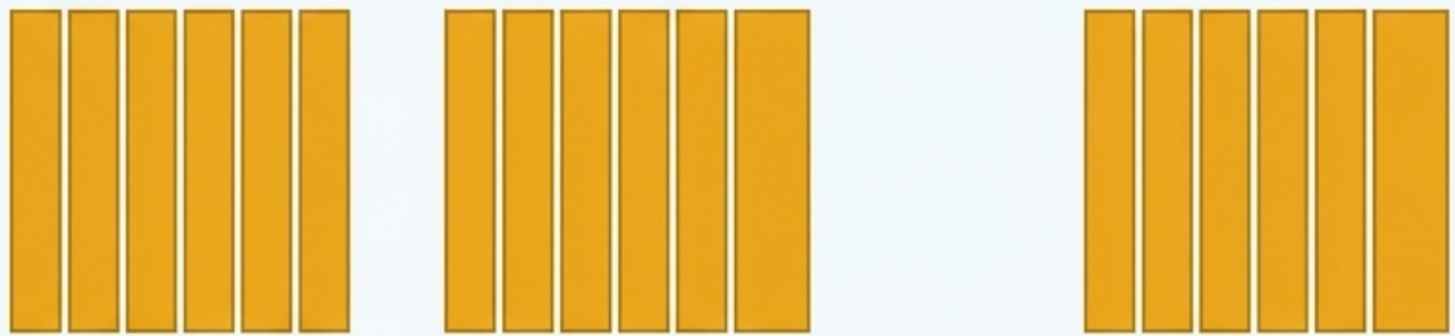
A Origem do Problema: Superparametrização

Insight: A matriz torna-se de posto incompleto quando inserimos mais parâmetros do que o estritamente necessário (ex: modelos de ANOVA).

Coluna do Intercepto (Tudo 1)

=

Variáveis Indicadoras (Dummies)



[Categoria 1] + [Categoria 2] + ... + [Categoria k]

Consequência: A Coluna 1 é a combinação linear exata da soma das colunas categóricas. O posto de X cai irremediavelmente.

Gemini Notebook

O Efeito Dominó Matemático

$\mathbf{X}$ possui dependência linear nas colunas

↓

Posto$(\mathbf{X}^{\mathrm{T}}\mathbf{X}) = r < p$

↓

Determinante $|\mathbf{X}^{\mathrm{T}}\mathbf{X}| = 0$

↓

A matriz não admite inversa usual $(\mathbf{X}^{\mathrm{T}}\mathbf{X})^{-1}$

↓

As Equações Normais ($\mathbf{X}^{\mathrm{T}}\mathbf{X}\hat{\boldsymbol{\beta}} = \mathbf{X}^{\mathrm{T}}\mathbf{y}$) passam a ter INFINITAS SOLUÇÕES

Problema de Identificabilidade

Os parâmetros $\boldsymbol{\beta}$ individuais não são identificáveis. Múltiplos conjuntos de estimativas levam ao exato mesmo ajuste espacial.

Gemini Notebook

A Ponte Teórica: A Inversa Generalizada (G)

Definição Base:
$\mathbf{A}^-$ é a inversa generalizada de $\mathbf{A}$ se $\mathbf{AA}^-\mathbf{A} = \mathbf{A}$.

Uma solução particular do sistema.

$$\hat{\boldsymbol{\beta}}^* = (\mathbf{X}^T\mathbf{X})^-\mathbf{X}^T\mathbf{y} + \left[\mathbf{I} - (\mathbf{X}^T\mathbf{X})^-\mathbf{X}^T\mathbf{X}\right]\mathbf{Z}$$

A Inversa Generalizada de $\mathbf{X}^T\mathbf{X}$.

Vetor arbitrário. Para cada vetor $\mathbf{Z}$ escolhido, obtemos um $\hat{\boldsymbol{\beta}}^*$ diferente, gerando as infinitas soluções.

Gemini Notebook

A Magia da Invariância: O Que Sobrevive?

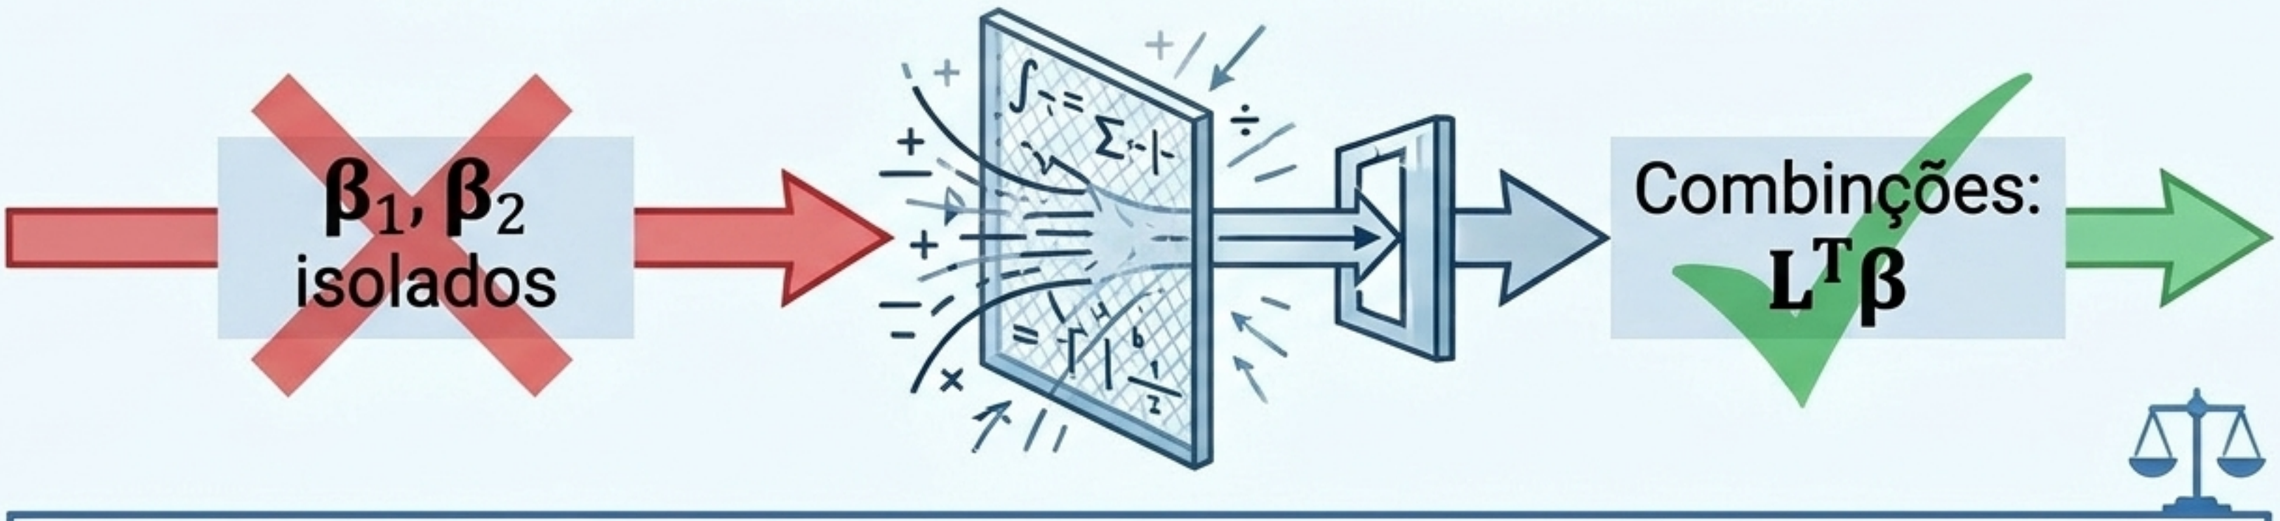
Mesmo com infinitas soluções para o vetor de parâmetros, fundamentais **propriedades do modelo permanecem blindadas**.

Valores Ajustados $\hat{\mathbf{y}} = \mathbf{X}\hat{\boldsymbol{\beta}}^*$ O vetor de predição é único.	Matriz de Projeção $\mathbf{H} = \mathbf{X}(\mathbf{X}^\mathbf{T}\mathbf{X})^{-}\mathbf{X}^\mathbf{T}$ A matriz $\mathbf{H}$ continua sendo ortogonal e única.
Resíduos SQR A Soma de Quadrados dos Resíduos é invariante a qualquer $(\mathbf{X}^\mathbf{T}\mathbf{X})^{-}$.	Variância do Erro $\hat{\sigma}^2 = \frac{\mathrm{SQR}}{n-r}$ Estimador permanece válido, ajustando os graus de liberdade para o posto $\mathbf{r}$.

Gemini Notebook

Funções Estimáveis: Medindo Combinações

Não podemos estimar os parâmetros $\boldsymbol{\beta}$ individuais de forma única, mas podemos estimar certas combinações lineares deles.



Definição Formal: $\mathbf{L}^T\boldsymbol{\beta}$ é estimável se existir um estimador linear não viesado $\mathbf{T}^T\mathbf{y}$.

Condição de Existência: $\mathbf{L}^T = \mathbf{T}^T\mathbf{X}$

O vetor $\mathbf{L}^T$ deve pertencer obrigatoriamente ao espaço linha da matriz $\mathbf{X}$.
O número máximo de funções estimáveis independentes é igual ao posto $\mathbf{r}$.

Gemini Notebook

O Teorema de Gauss-Markov Estendido

Teorema Central

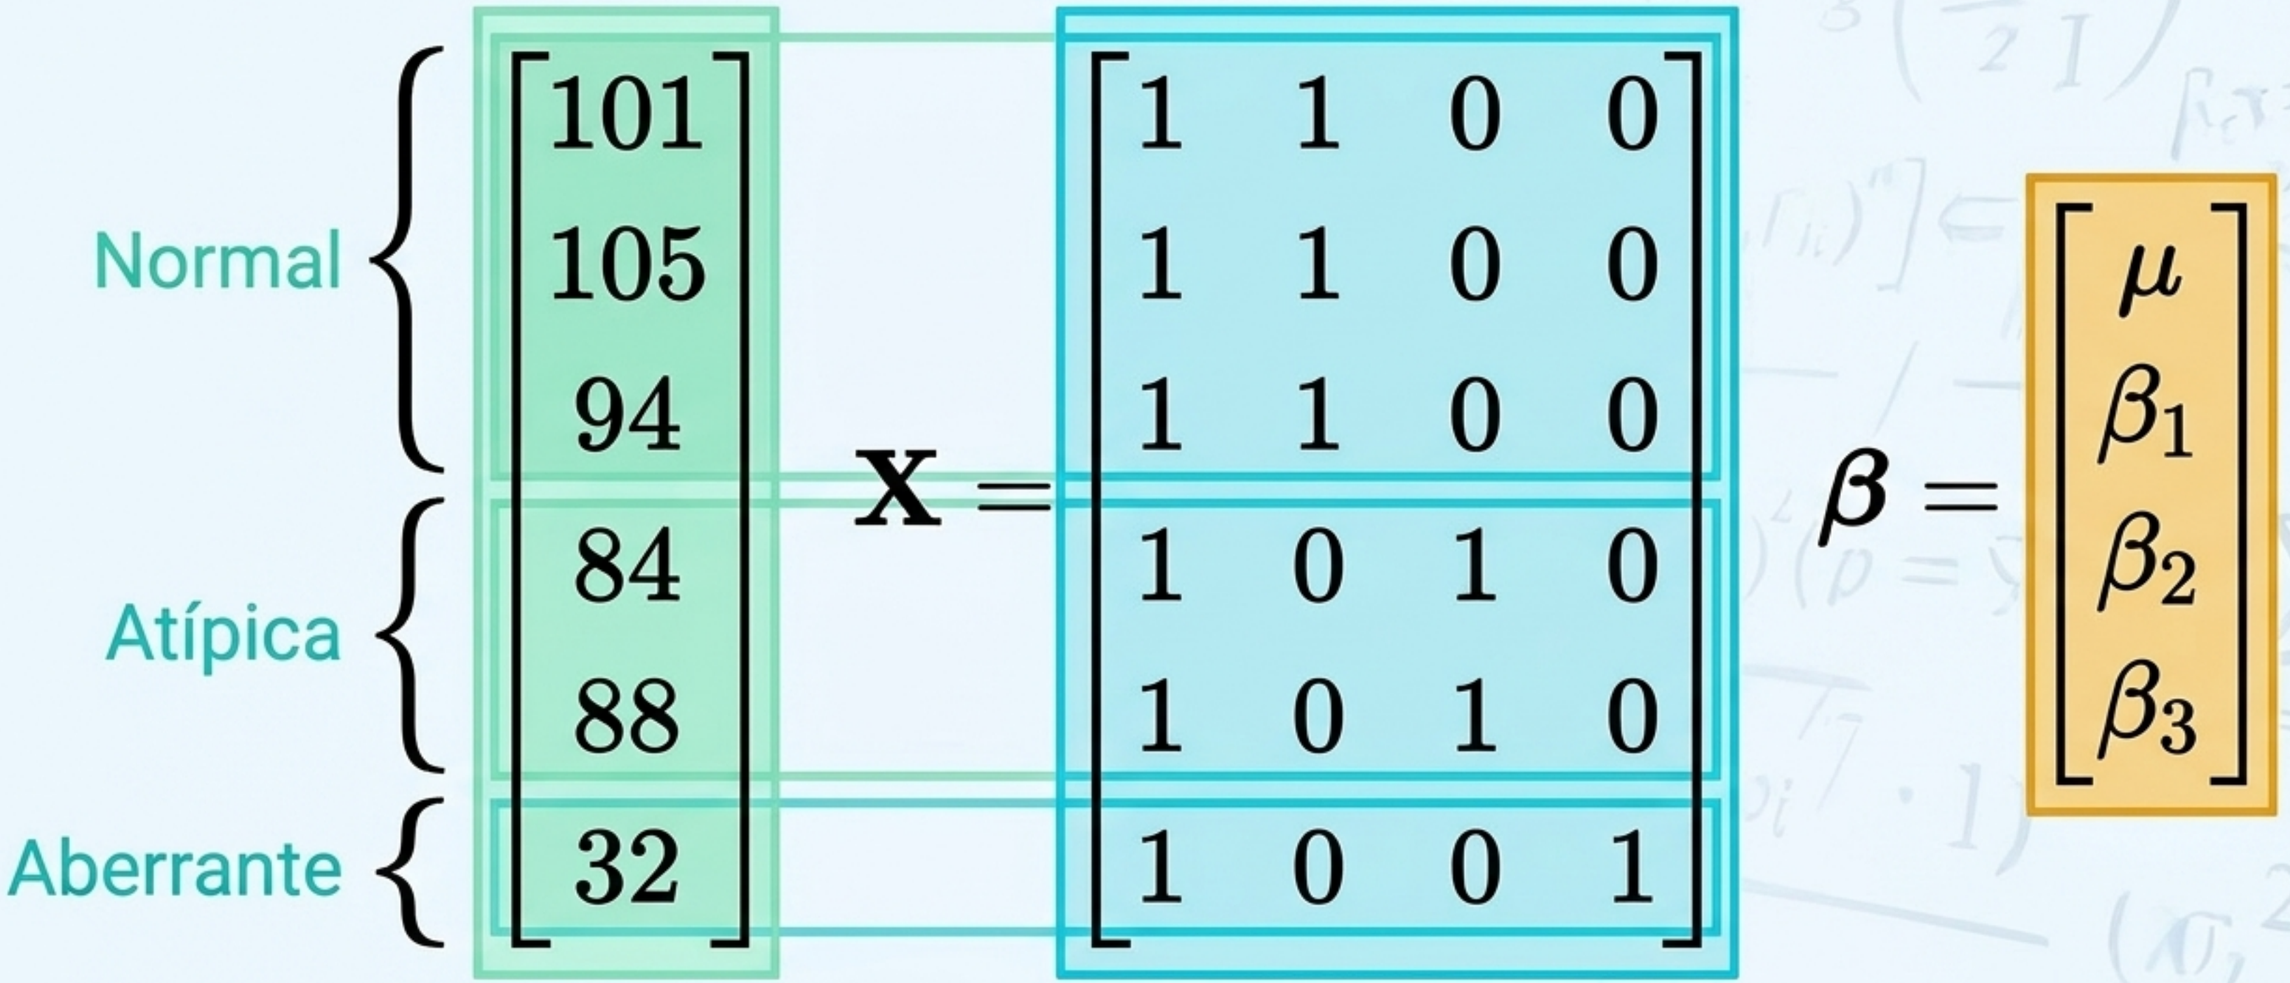
Se $\mathbf{L}^{\mathrm{T}}\boldsymbol{\beta}$ é uma função estimável num modelo de posto incompleto, então seu estimador $\mathbf{L}^{\mathrm{T}}\hat{\boldsymbol{\beta}} = \mathbf{L}^{\mathrm{T}}(\mathbf{X}^{\mathrm{T}}\mathbf{X})^{-}\mathbf{X}^{\mathrm{T}}\mathbf{y}$ é único e invariante a qualquer escolha de inversa generalizada.

- **Propriedade BLUE**: Este é o Melhor Estimador Linear Não Viesado para $\mathbf{L}^{\mathrm{T}}\boldsymbol{\beta}$.
- **Variância**: $V\left(\mathbf{L}^{\mathrm{T}}\hat{\boldsymbol{\beta}}\right) = \sigma^2\mathbf{L}^{\mathrm{T}}(\mathbf{X}^{\mathrm{T}}\mathbf{X})^{-}\mathbf{L}$
- **Testes de Hipóteses**: Apenas hipóteses baseadas em funções estimáveis ($H_0: \mathbf{K}^{\mathrm{T}}\boldsymbol{\beta} = M$) são logicamente testáveis.

Gemini Notebook

Estudo de Caso: Pesos de Plantas (Mapeamento Correto)

6 observações de plantas: 3 Normais, 2 Atípicas, 1 Aberrante.



Gemini Notebook

O Diagnóstico Numérico em X^TX

$$X^TX = \begin{bmatrix} \begin{bmatrix} 6 \\ 3 \\ 2 \\ 1 \end{bmatrix} + \begin{bmatrix} 3 \\ 3 \\ 0 \\ 0 \end{bmatrix} + \begin{bmatrix} 2 \\ 0 \\ 2 \\ 0 \end{bmatrix} + \begin{bmatrix} 1 \\ 0 \\ 0 \\ 1 \end{bmatrix} \end{bmatrix} =$$

[Coluna 1] = [Coluna 2] + [Coluna 3] + [Coluna 4]

O **posto de X^TX** é 3 (menor que o número de parâmetros 4). O determinante zera.

Exemplo de Função Estimável: μ não pode ser estimado isolado, mas a combinação $[\mu + \beta_1]$ é perfeitamente estimável (Base: $L^T = [1, 1, 0, 0]$).

Gemini Notebook

Soluções Pragmáticas na Prática Estatística

Como evitar a inversa generalizada no dia a dia (Software/Modelagem).

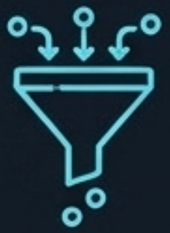
1. Reparametrização



Alterar a parametrização removendo colunas redundantes para forçar o posto completo.

Exemplo: Definir uma categoria base (Casela de Referência).

2. Redução e Seleção



Remover variáveis colineares do modelo ou aplicar técnicas de compressão do espaço vetorial, como PCA (Componentes Principais).

3. Regularização



Essencial para quase-singularidade (determinante muito próximo de zero).

Uso de penalizações nas matrizes como regressão Ridge, Lasso ou Elastic Net para evitar overflow.

Gemini Notebook

Reparametrização no R (Da Lousa para o Terminal)

Casela de Referência (Default do R)

Omite a dummy da categoria base (valores tornam-se 0). A matriz retorna ao posto completo.

Interpretação: O intercepto (μ) passa a representar a média exata da categoria base.

```r
# R Code: Casela de Referência
data <- data.frame(Y = c(5, 7, 6, 8, 7),
                   Group = factor(c("A", "A", "B", "B", "B")))
data$Group <- relevel(data$Group, ref = "A") # 'A' é a base
model_ref <- lm(Y ~ Group, data = data)
summary(model_ref)
```

```
     (Intercept) GroupB
[1,]           1      0
[2,]           1      0
[3,]           1      1
[4,]           1      1
[5,]           1      1
```

← Matriz de Design (X) - Posto Completo

Desvios Médios (Contrastes)

Codifica a variável categórica usando valores 1, 0 e -1.

Interpretação: Os parâmetros estimam o desvio de cada nível específico em relação à média geral.

```r
# R Code: Desvios Médios (Contrastes)
data <- data.frame(Y = c(5, 7, 6, 8, 7),
                   Group = factor(c("A", "A", "B", "B", "B")))
contrasts(data$Group) <- contr.sum(2) # Contrastes de soma
model_contr <- lm(Y ~ Group, data = data)
summary(model_contr)
```

```
     (Intercept) Group1 (contraste)
[1,]           1                  0
[2,]           1                  0
[3,]           1                 -1
[4,]           1                 -1
[5,]           1                 -1
```

← Matriz de Design (X) - Posto Completo

Takeaway Final: Ambas as abordagens curam o problema matemático do posto incompleto; a escolha afeta exclusivamente a interpretação dos parâmetros ajustados.

Gemini Notebook