Modelos Lineares Generaizados

Estimação de Parâmetros, Motor Iterativo e Diagnóstico em Machine Learning.

Legenda Visual

β	Vetor de parâmetros
μ	Média
W/V	Matriz de Pesos / Função de Variância
Y	Resposta

Gemini Notebook

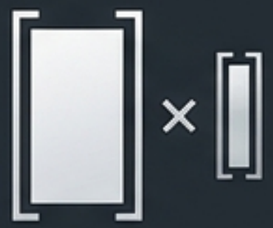
A Arquitetura de um MLG



Componente Aleatório

A variável resposta Y pertence à Família Exponencial de distribuições.

$$Y \sim \text{Família Exponencial}(\mu, \phi)$$



Preditor Linear

A combinação linear das variáveis explicativas.

$$\eta = X\beta$$



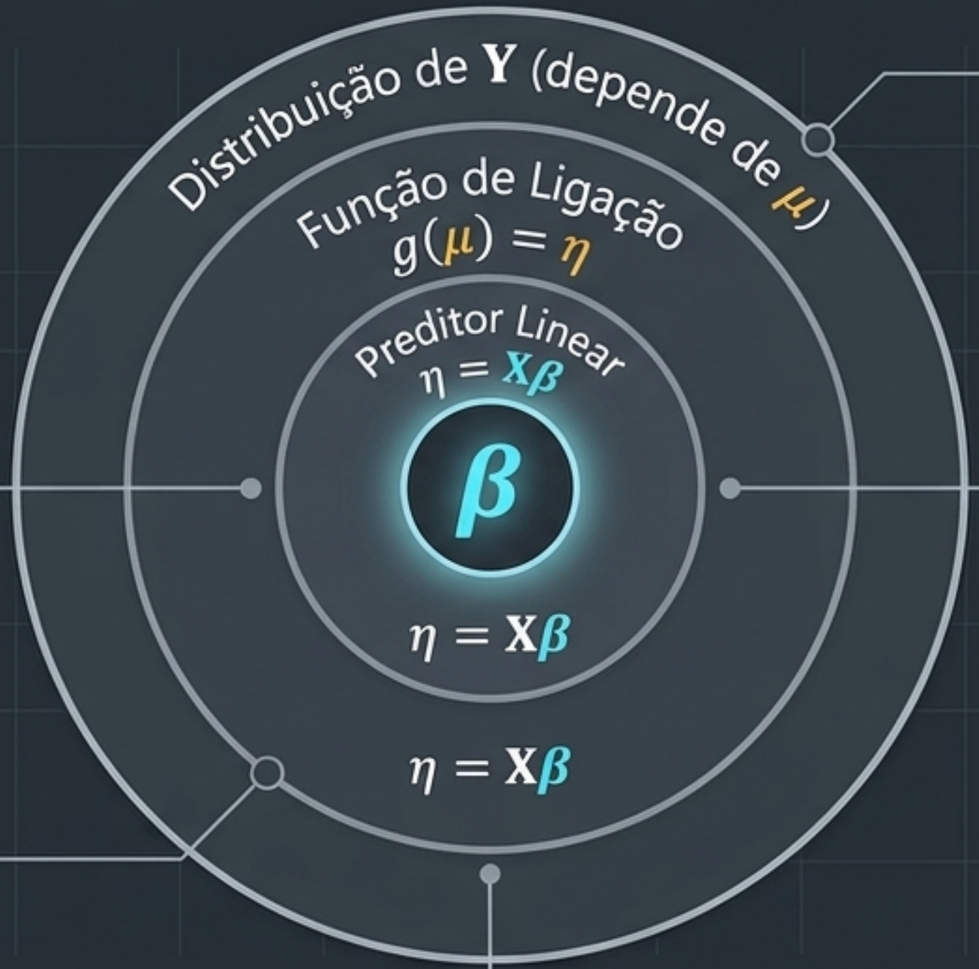
Função de Ligação

A função $g(\cdot)$ que conecta a média da resposta ao preditor linear.

$$g(\mu) = \eta$$

Gemini Notebook

O Desafio da Não-Linearidade



$$\hat{\boldsymbol{\beta}}(\mathbf{X}^T\mathbf{X})^{-1}\mathbf{X}^T\mathbf{Y}$$

O Método Clássico Falha

Em Modelos Lineares, estimamos $\boldsymbol{\beta}$ via Mínimos Quadrados Ordinários (MQO):

$$\hat{\boldsymbol{\beta}} = (\mathbf{X}^T\mathbf{X})^{-1}\mathbf{X}^T\mathbf{Y}$$

O Bloqueio nos MLGs

Como $\boldsymbol{\beta}$ está "preso" dentro de uma função de ligação não-linear $g(\mu)$, não existe uma solução algébrica fechada.

A Solução: Maximizar a Função de Verossimilhança através de métodos numéricos iterativos.

Gemini Notebook

Desconstruindo a Log-Verossimilhança

Log-Verossimilhança:
O logaritmo natural neutraliza a exponencial da função densidade, simplificando a maximização.

Parâmetro Canônico:
Relacionado à média μ.

Função Cumulante:
Sua derivada primeira nos dá a média μ.

$$l(\theta, \varphi; y) = \sum \left[\frac{y_i \theta_i - b(\theta_i)}{\varphi} + c(y_i, \varphi) \right]$$

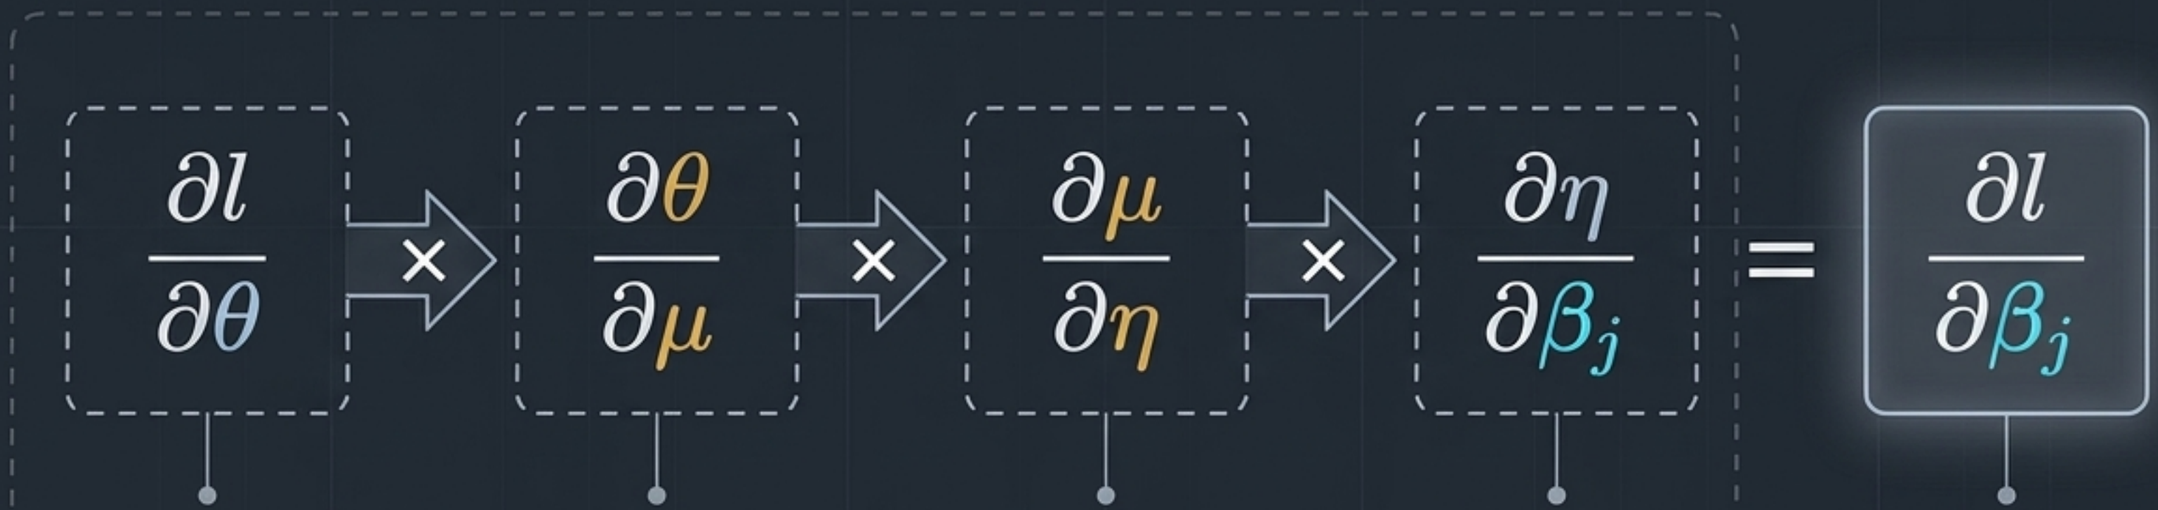
Parâmetro de Dispersão:
Assumido como conhecido inicialmente para focar na estimação de β.

O objetivo é derivar l em relação a β e igualar a zero. Mas como β não aparece diretamente na fórmula, precisamos da Regra da Cadeia.

Gemini Notebook

A Regra da Cadeia para a Função Score

Para estimar os parâmetros, o método de Máxima Verossimilhança exige derivar l em relação a β. Construímos essa derivada conectando cada camada do modelo.



Gemini Notebook

A Função Score: U(β)

$$U(\beta_j) = \sum \left[\frac{Y_i - \mu_i}{V(\mu_i)} \cdot \frac{\partial \mu_i}{\partial \eta_i} \cdot X_{ij} \right] = 0$$

O Resíduo Bruto:
A diferença entre o valor observado e a média estimada.

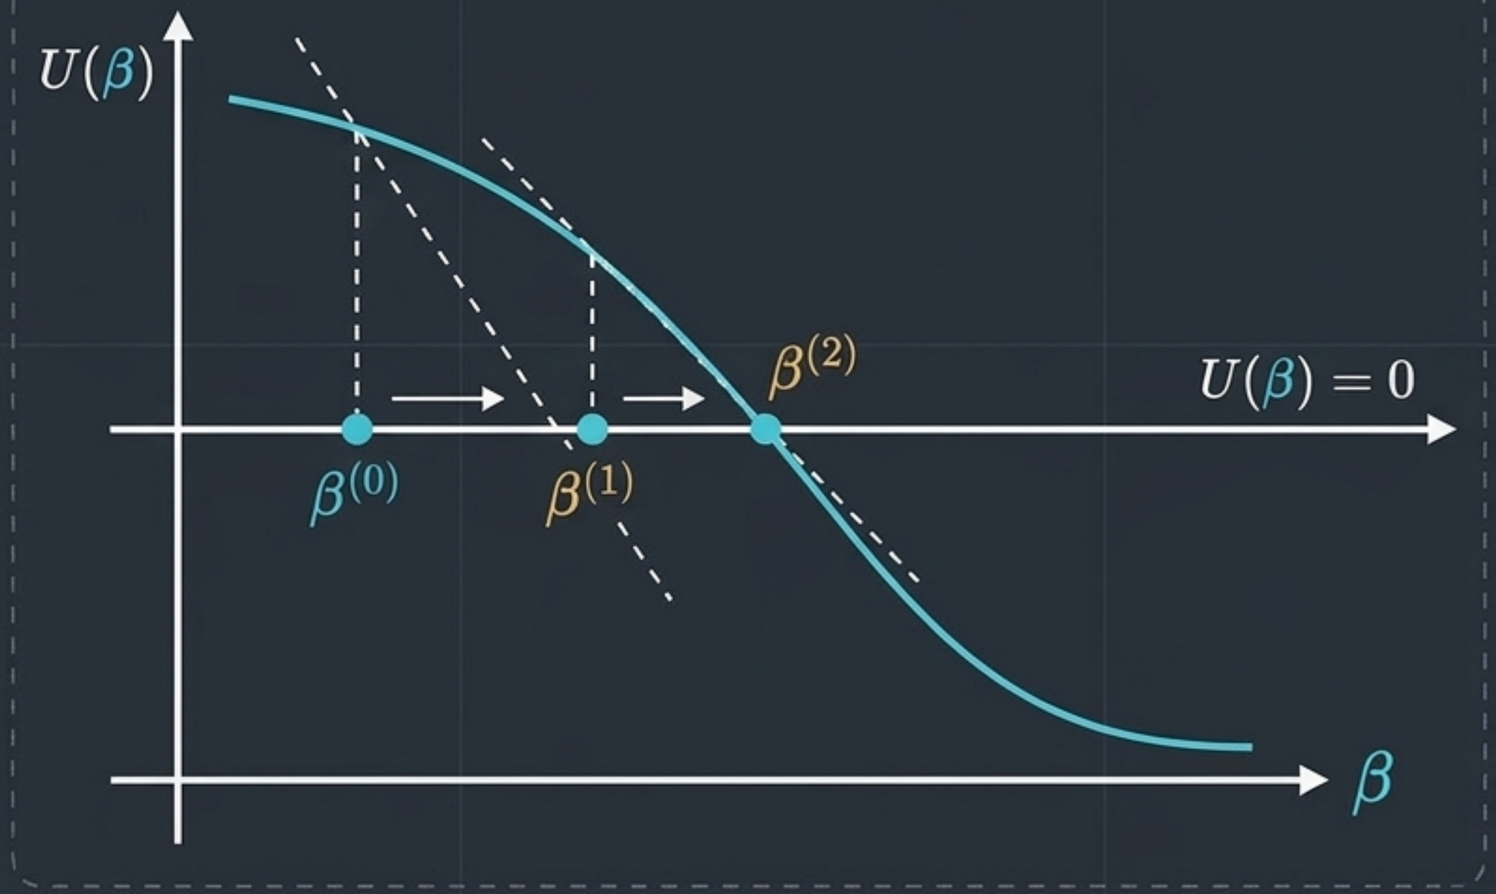
Função de Variância:
Penaliza observações com maior variância.

A Covariável:
O valor do preditor.

Igualar o Vetor Score a zero (**U(β) = 0**) define o ponto máximo. Porém, a **não-linearidade** impede o isolamento algébrico de **β**. Entramos no Motor Iterativo.

Gemini Notebook

Encontrando o Zero (Métodos Numéricos)



O Problema

Não podemos resolver $U(\beta) = 0$ diretamente.

A Solução Numérica

Partimos de um chute inicial $\beta^{(0)}$ e usamos a derivada da Função Score (a Matriz de Informação) para guiar os passos iterativos até a convergência.

Gemini Notebook

Newton-Raphson vs. Fisher Scoring

	Newton-Raphson	Fisher Scoring
Matriz Utilizada	Matriz de Informação Observada (J)	Matriz de Informação Esperada (K)
Definição Matemática	Derivada segunda exata da log-verossimilhança: $$J = -\frac{\partial^2 \ell}{\partial \beta \partial \beta^T}$$	O valor esperado da derivada segunda: $$K = \mathbb{E}[J]$$
Aplicação Prática	Computacionalmente mais custoso em modelos complexos.	O padrão na maioria dos softwares estatísticos para MLGs. Mais estável. Para ligação canônica, $J = K$.

Gemini Notebook

A Matriz de Pesos (W) e a Forma Matricial

A Anatomia de W

Para simplificar a estimação, softwares agrupam a variância e a derivada da função de ligação em uma matriz diagonal de pesos W:

$$W_i = \left(\frac{\partial \mu_i}{\partial \eta_i}\right)^2 \frac{1}{V(\mu_i)}$$

As Fórmulas Matriciais

Com W definido, as expressões colapsam em álgebra linear limpa:

Vetor Score:

$$U(\beta) = X^T W^{1/2} V^{-1/2} (Y - \mu)$$

Matriz de Informação (Fisher):

$$K = X^T W X$$

A forma matricial não é apenas um atalho de notação; é a exata arquitetura programada internamente em pacotes como `glm` no R.

Gemini Notebook

O Algoritmo IRLS (Mínimos Quadrados Reponderados Iterativamente)

Passo 1: Definir chute inicial $\beta^{(0)}$ (geralmente $\mu_i = Y_i$).

Passo 2: Calcular a Matriz de Pesos W e o Vetor Score U na iteração m.

Passo 3: Atualizar o vetor β (equação central).

$$\beta^{(m+1)} = \beta^{(m)} + K^{-1}U(\beta^{(m)})$$

Passo 4: Checar convergência. O erro relativo máximo entre $\beta^{(m+1)}$ e $\beta^{(m)}$ é menor que ε (ex: 10^{-3})?

Se NÃO → Repete o ciclo.

Se SIM → Modelo ajustado.

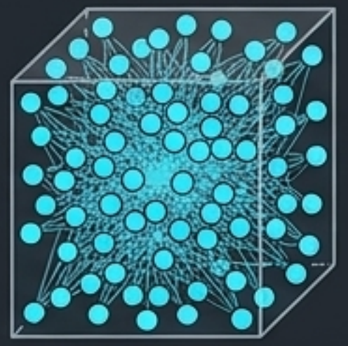
Se NÃO → Repete o ciclo.

Contexto: Este é o verdadeiro 'motor' rodando por trás do comando de ajuste no seu software estatístico.

Gemini Notebook

O Diagnóstico: A Função Desvio (Deviance)

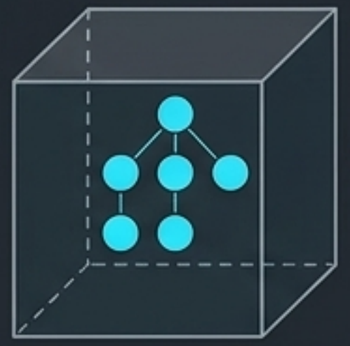
Modelo Saturado



n parâmetros (1 para cada observação).
$\mu_{hati} = Y_i$.

Ajuste perfeito aos dados (overfitting extremo), mas zero capacidade de generalização.

Modelo Ajustado



$p+1$ parâmetros (estimados via Máxima Verossimilhança).

O modelo real, simplificado, que busca explicar os dados de forma parcimoniosa.

O **Desvio Escalonado** (D^*) é o dobro da diferença das log-verossimilhanças entre esses dois extremos:

$$D^* = 2\left[\,\ell(\text{saturado}) - \ell(\text{ajustado})\,\right]$$

Insight: Valores menores de desvio indicam que nosso modelo ajustado conseguiu capturar a informação quase tão bem quanto o modelo saturado.

Gemini Notebook

Resíduos e Qualidade do Ajuste

O Resíduo Componente do Desvio

Diferente do modelo linear clássico, MLGs usam métricas de resíduos específicas. O padrão-ouro é o **Resíduo Componente do Desvio**.

Ele particiona o Desvio total $\mathcal{D}$ en n componentes individuais (d_i), permitindo avaliar o erro de cada observação de forma isolada.

Gráfico de Envelope



Validação de Suposições: O Gráfico de Envelope simula bandas de confiança. Se os resíduos componentes do desvio escaparem amplamente das bandas, a distribuição assumida (ex: Poisson vs. Binomial Negativa) pode estar incorreta.

Gemini Notebook

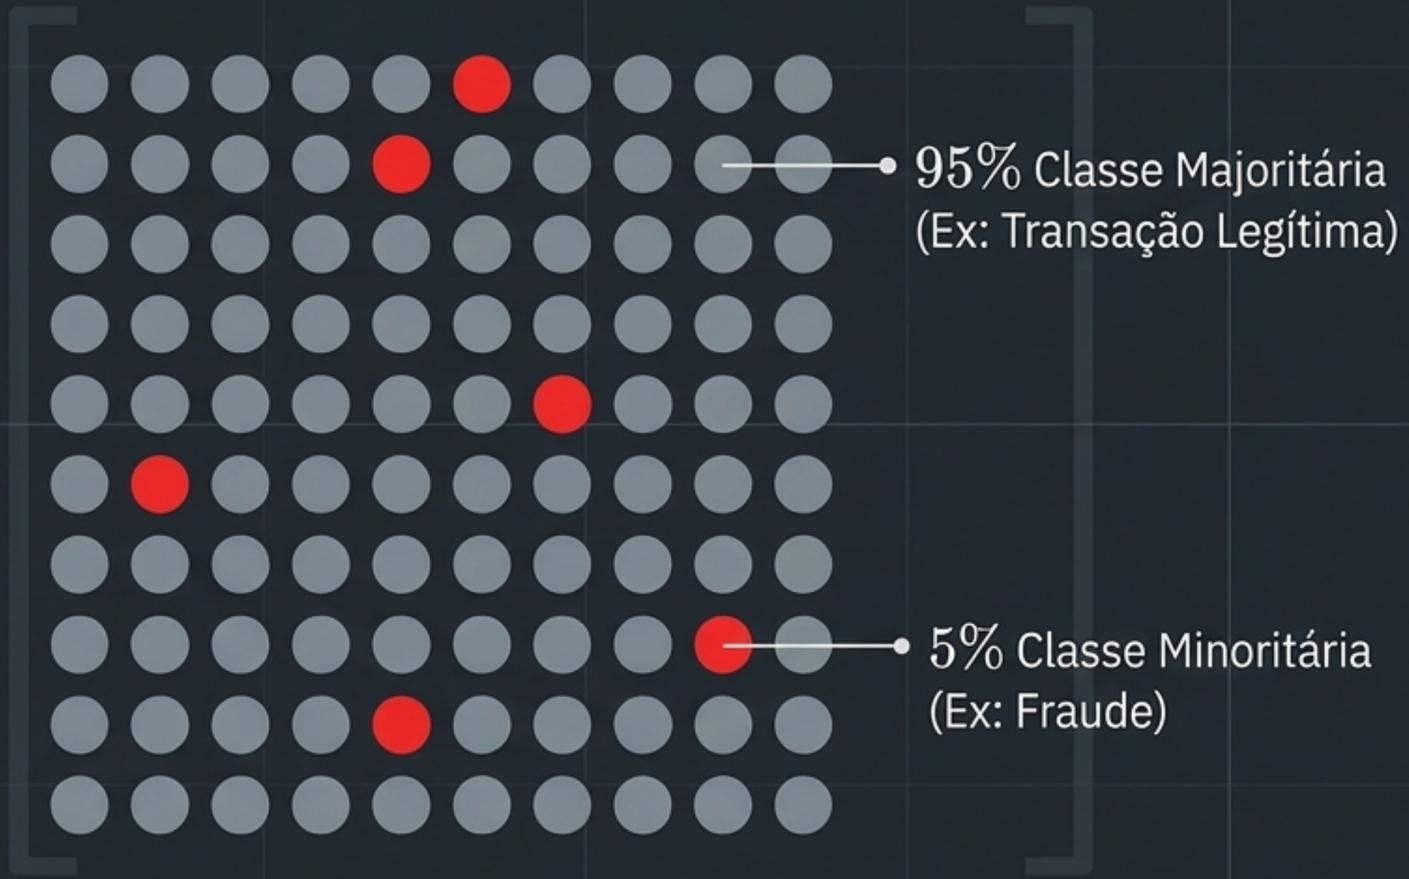
MLGs no Contexto de Machine Learning

Vocabulário Estatístico		Tarefa de Machine Learning
MLG Gaussiano (Normal)	<-->	Regressão Supervisada (Ex: Previsão de valores contínuos)
MLG Binomial/Bernoulli	<-->	Classificação Supervisada Binária
Função de Ligação Logit	<-->	Regressão Logística (Classificador de Spam, Fraude)
Estimação de Máxima Verossimilhança	<-->	Otimização de Loss / Treinamento do Modelo

O Aprendizado de Máquina foca na predição e performance geral, enquanto a modelagem estatística tradicional foca fortemente na interpretação dos parâmetros (β) e na validade das inferências.

Gemini Notebook

O Risco da Acurácia em Dados Desbalanceados



O Cenário:

Em problemas reais (fraude, doenças raras), uma classe domina quase todos os dados.

A Armadilha:

Um modelo ingênuo que simplesmente chuta “Não é fraude” para tudo obterá 95% de Acurácia.

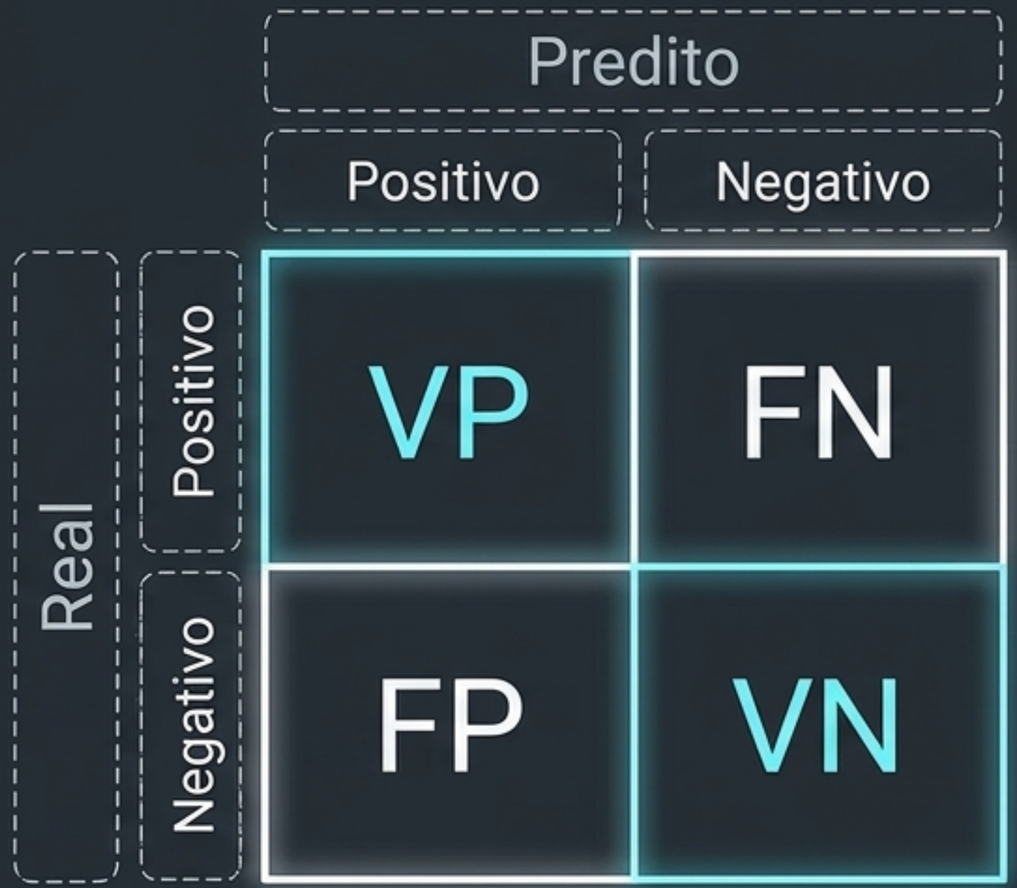
O Resultado:

Falsa sensação de performance. O modelo é inútil para o seu propósito principal (detectar os 5% de fraudes).

Como demonstrado na literatura (ex: artigo Performance Metrics for Imbalanced Data, Cruz et al.), a acurácia global mascara o erro crítico nas classes minoritárias.

Gemini Notebook

Métricas Robustas e a Matriz de Confusão



Alternativas Robustas

Em vez de Acurácia, a prática moderna para MLGs em dados desbalanceados exige:

1 **G-Mean (Média Geométrica)**

Equilibra a **sensibilidade** e a **especificidade**. Penaliza o modelo se ele ignorar a **classe minoritária**.

2 **Kappa de Cohen**

Ajusta a **performance** removendo a **probabilidade** de **acertos** puramente ao acaso.

Pronto para uso: Pacotes `statsmodels` (Python) e `glm` (R) fornecem os motores de estimação IRLS. As bibliotecas de ML complementam com estas métricas nativas.

Gemini Notebook