Modelos Lineares Modelos Lineares Generalizados (MLGs)

Condições de Regularidade, Família Exponencial e Funções de Ligação.

EST5507 – Modelos de Regressão | Material de Apoio à Aula.

Gemini Notebook

A Evolução para os MLGs

Modelo Linear Clássico	Modelo Linear Generalizado (MLG)
• **Resposta:** Restrita à Distribuição Normal. • **Ligação:** Estritamente Identidade ($\mu = \eta$). • **Limitação:** Inadequado para contagens, proporções ou assimetrias severas.	• **Resposta:** Flexível (Qualquer distribuição da Família Exponencial). • **Ligação:** Funções variadas (Log, Logito, Probito, etc.). • **Vantagem:** Modela perfeitamente contagens, proporções, valores estritamente positivos e dados assimétricos.

Os MLGs não são apenas uma ferramenta, mas uma base arquitetural. **Eles servem servem como alicerce para expansões ainda mais complexas, como modelos com efeitos aleatórios e dispersão flexível.**

Gemini Notebook

O Coração do MLG: A Família Exponencial

Variável resposta (sempre acompanhando o parâmetro θ).

Parâmetro canônico (pertencente ao espaço paramétrico Θ). Relaciona-se com a média.

$$f(y;\theta,\varphi) = \exp\{\varphi[y\theta - b(\theta)] + c(y,\varphi)\}$$

Termo independente de θ.

Parâmetro de dispersão (multiplica o núcleo principal da fórmula). Condição: $\varphi > 0$.

Função estritamente associada ao parâmetro natural. Fundamental para extrair Média e Variância.

Condição vital: As funções $b(\theta)$ e $c(y, \varphi)$ devem ser diferenciáveis. O MLG depende de derivadas para a estimação por Máxima Verossimilhança.

Gemini Notebook

A Arquitetura de um MLG (Os 3 Pilares)

1. O Componente Aleatório

$Y_1, \ldots, Y_n$ são independentes (não identicamente distribuídos).

Distribuídos segundo a Família Exponencial.

Cada Y_i possui média μ_i e dispersão ϕ.

Covariáveis $X_1, ..., X_p$ são assumidas como fixadas/conhecidas.

2. A Parte Sistemática (Preditor Linear)

Agrega o efeito das covariáveis.

$$\eta_i = \beta_0 + \beta_1 x_{1i} + \ldots + \beta_p x_{pi} = x_i^T \beta$$

3. A Função de Ligação (g)

A ponte matemática. Função monótona e diferenciável.

Conecta a média da resposta ao preditor linear:

$$g(\mu_i) = \eta_i$$

Gemini Notebook

O Papel da Função de Ligação $g(\mu)$

A **função de ligação** $g(\mu)$ permite modelar uma função da média de Y, não a média direta, garantindo que as predições respeitem o espaço paramétrico de Y (ex: probabilidades estritamente entre 0 e 1).



Identidade: $g(\mu) = \mu$

Log: $g(\mu) = \log(\mu)$

Logito (Logit): $g(\mu) = \log\left(\frac{\mu}{1-\mu}\right)$

Probito (Probit): $g(\mu) = \Phi^{-1}(\mu)$

C-Log-Log: $g(\mu) = \log(-\log(1-\mu))$

Recíproca: $g(\mu) = -1/\mu$

O modelo de **regressão logística** (resposta Binomial + ligação Logito) é amplamente favorecido pela sua interpretação natural via **Razão de Chances** (Odds Ratio).

Gemini Notebook

Insight Prático: Dados Desbalanceados

O Problema Real

Modelagem de eventos raros ou anomalias (ex: Detecção de Fraudes em cartões de crédito), onde a classe classe minoritária representa uma fração mínima dos dados.

A Armadilha Prática

Modificar os dados via **Under/Oversampling** puramente para forçar o ajuste de uma regressão logística padrão.

- **Consequência:** Perda massiva de informação real; a métrica de **Acurácia** torna-se uma ilusão matemática.

A Solução (Estado da Arte)

1. Substituir a ligação canônica simétrica (Logito) por **Funções de Ligação Assimão Assimétricas**.
2. Avaliar o modelo com métricas estritamente **robustas** ao desbalanceamento, como a Média Geométrica ou o Kappa de Cohen.

Gemini Notebook

O Motor Matemático: Condições de Regularidade

Para estimar parâmetros maximizando a verossimilhança, trabalhamos com a Log-Verossimilhança (L). Como o logaritmo é uma função monótona crescente, ele simplifica drasticamente as derivadas da Família Exponencial, preservando o ponto de máximo exato.

1. Função Score Esperada

A esperança da derivada primeira (Score) é zero.

$$\mathbb{E}\left[\frac{\partial L}{\partial \theta}\right] = 0$$

2. Informação de Fisher

A esperança da derivada segunda é igual a menos a esperança do quadrado da derivada primeira.

$$\mathbb{E}\left[\frac{\partial^2 L}{\partial \theta^2}\right] = -\mathbb{E}\left[\left(\frac{\partial L}{\partial \theta}\right)^2\right]$$

Gemini Notebook

O Grande Resultado: Média e Variância

Base: A contribuição da observação i para a Log-Verossimilhança:

$$L_i = \varphi(y_i\theta - b(\theta)) + c(y_i, \varphi)$$

Valor Esperado (Média)

Aplicando a 1ª condição de regularidade, a média é simplesmente a derivada primeira de b(**θ**).

$$\mathbb{E}[Y] = \mu = b'(\theta)$$

Variância da Resposta

Aplicando a 2ª condição de regularidade, extraímos a variância:

$$\mathrm{Var}(Y) = \frac{b''(\theta)}{\phi}$$

Definição vital: V(**μ**) = b''(**θ**) é a Função de Variância. Ela define exatamente como a dispersão da distribuição evolui em função da sua média.

Gemini Notebook

Caso Prático 1: Dissecando o Modelo Poisson (Setup)

Passo 1: A Função Massa Original

$$f(y;\mu) = \frac{e^{-f}\mu^{y}}{y!}$$

Passo 2: Transformação Exponencial e Logarítmica

Aplicando base 'e' e 'log' para forçar o formato da família exponencial:

$$f(y;\mu) = \exp\{y\log(\mu) - \mu - \log(y!)\}$$

Passo 3: Mapeamento para a Família Exponencial

$$\theta = \log(\mu)$$
$$b(\theta) = \mu$$
$$\varphi = 1$$
$$c(y,\varphi) = -\log(y!)$$



Gemini Notebook

Caso Prático 1: Modelo Poisson (Derivadas)

Sabemos pelo mapeamento que $\theta = \log(\mu)$. Invertendo a relação, temos $\mu = e^{\theta}$.
Como o mapeamento também mostrou que $b(\theta) = \mu$, concluímos que:

$$b(\theta) = e^{\theta}$$

Aplicando os Teoremas Deduzidos:

1ª Derivada (Calculando a Média):

$$b'(\theta) = e^{\theta} = \mu \Rightarrow E[Y] = \mu$$

2ª Derivada (Calculando a Variância):

$$b''(\theta) = e^{\theta} = \mu$$

Sabemos que $Var(Y) = \frac{b''(\theta)}{\phi}$. Como $\phi = 1$ e $b''(\theta) = \mu$: $Var(Y) = \mu$

Conclusão: Comprovamos matematicamente a propriedade estrutural mais famosa da distribuição Poisson: a Média é igual à Variância, sendo a Função de Variância $V(\mu) = \mu$.

Gemini Notebook

Caso Prático 2: Dissecando o Modelo Binomial (Setup)

Definição Crucial: Modelaremos Y^* (a proporção de sucessos em n ensaios independentes de Bernoulli). Logo, $nY^* \sim Binomial(n, \mu)$.

A Função Massa Original

$$f(y^*; \mu) = C(n, n_y^*)\, \mu^{n_{y^*}}\, (1-\mu)^{n-n_{y^*}}$$

Transformação Estratégica (Log / Exp):

$$f(y^*; \mu) = \exp\left\{n_y^* \log(\mu) + (n - n_y^*) \log(1-\mu) + \log C(n, n_y^*)\right\}$$

Agrupando a Variável de Interesse (n_y^*):

$$f(y^*; \mu) = \exp\left\{n_y^* \log\left(\frac{\mu}{1-\mu}\right) + n \log(1-\mu) + \log C(n, n_y^*)\right\}$$

Gemini Notebook

Caso Prático 2: Modelo Binomial (Parâmetros)

$$\exp\left\{n_y^* \log\left(\frac{\mu}{1-\mu}\right) + n\log(1-\mu) + \log C(n, n_y^*)\right\}$$

Dispersão (ϕ):	Função $b(\theta)$:	Termo $c(y^*, \phi)$:	Parâmetro Natural (θ):
n	$-\log(1-\mu)$	$\log C(n, n_y^*)$	$\log\left(\frac{\mu}{1-\mu}\right)$

O nascimento orgânico da função Logito!

A **Derivada Binomial:** Ao expressar μ em função de θ, obtemos $\mu = \frac{e^\theta}{1+e^\theta}$. Derivando $b(\theta)$ duas vezes utilizando a regra do quociente, obtemos o resultado clássico para a Função de Variância: $V(\mu) = \mu(1-\mu)$

Gemini Notebook

O Conceito de Ligação Canônica

Parâmetro Natural (θ_i) = **Preditor Linear (η_i)**

$$\theta_i = \eta_i = \boldsymbol{x}_i^T \boldsymbol{\beta}$$

A **Ligação Canônica** ocorre quando assumimos perfeitamente que o parâmetro natural intrínseco da distribuição é matematicamente idêntico à parte sistemática do modelo.

1. Na **Poisson**: Vimos que $\theta = \log(\mu)$. Se modelarmos $\eta = \log(\mu)$, criamos o Modelo Log-Linear (Ligação Canônica = Log).
2. Na **Binomial**: Vimos que $\theta = \log\left(\frac{\mu}{1-\mu}\right)$. Se modelarmos $\eta = \text{Logito}(\mu)$, criamos a Regressão Logística pura.

Gemini Notebook

Matriz de Síntese dos MLGs (O Manual)

Distribuição	Ligação Canônica $g(\mu)$	Função de Variância $V(\mu)$
Normal	Identidade (μ)	1
Poisson	Log $(\log(\mu))$	μ
Binomial	Logito $\left(\log\left(\frac{\mu}{1-\mu}\right)\right)$	$\mu(1-\mu)$
Gama	Recíproca $(-1/\mu)$	μ^2
Normal Inversa	Inversa Quadrática $\left(\frac{-1}{2\mu^2}\right)$	μ^3

Esta tabela arquitetural encapsula as escolhas matemáticas padrões adotadas pela esmagadora maioria dos softwares estatísticos modernos.

Gemini Notebook

Da Teoria ao Código

```
import statsmodels.api as sm

# Ajuste de MLG Binomial (Regressão Logística)
modelo = sm.GLM(y, X, family=sm.families.Binomial(link=sm.families.links.logit()))
resultado = modelo.fit()
```

Instancia a arquitetura generalizada do modelo.

Define a Distribuição da Família Exponencial (O Componente Aleatório).

Define a Função de Ligação (Nota: na ausência deste argumento explícito, o Python assume automaticamente a ligação canônica).

Próximos Passos: Na próxima aula, exploraremos como o `modelo.fit()` realmente funciona sob o capô — desvendando a matemática por trás do Processo Iterativo de Estimação de Parâmetros.

Gemini Notebook