Modelos Lineares Generalizados (MLGs): Qualidade do Ajuste e Estimação

Do Teorema à Implementação (IRLS e Python)

Baseado na aula da Prof. Cibele Russo — Pós-Graduação em Estatística

Gemini Notebook

O Paradigma: Estatística vs. Predição



Foco Preditivo

Objetivo
Desempenho em dados não vistos (Machine Learning).
Métricas
Erro Quadrático Médio (MSE), Erro Absoluto Médio.
Validação
Divisão da base (Treino/Teste).



Foco Estatístico (Nesta Aula)

Objetivo
Interpretação de parâmetros e adequação do modelo aos dados observados.
Métricas
Função Desvio (*Deviance*), Análise de Resíduos.
Validação
Ajuste usando toda a base de dados via inferência na região dos dados.

Gemini Notebook

O Espectro de Modelagem: O que estamos comparando?

Modelo Saturado



$\hat{\mu}_i = y_i$

Um parâmetro para cada observação (n parâmetros).

Ajuste perfeito, mas zero poder de síntese. Superparametrizado.

Modelo Proposto



$\hat{\mu}_i = g^{-1}(x_i^T \hat{\beta})$

Usa covariáveis para estimar $\hat{\mu}_i$ com p parâmetros ($p < n$).

Busca parcimônia e síntese de informações.

A **Função Desvio** avalia a diferença de informação (log-verossimilhança) entre esses dois extremos.

Gemini Notebook

A Função Desvio (Deviance)

Desvio Escalonado (D^*): Relacionado à razão de verossimilhanças. Diferente do Deviance fornecido em softwares (D), onde $D^* = D/\phi$.

Multiplicador matemático necessário para buscar aproximação com a distribuição χ^2.

$$D^* = 2\left[\ell(\text{Modelo Saturado}) - \ell(\text{Modelo Proposto})\right]$$

Log-verossimilhança máxima usando $\hat{\mu}_i = y_i$.

Log-verossimilhança máxima estimada com $\hat{\beta}$.

A aplicação do logaritmo transforma a razão de verossimilhanças em uma diferença, simplificando o cálculo.

Gemini Notebook

Dedução do Modelo Saturado (Família Exponencial)

Passo 1: Log-verossimilhança base

$$\ell_i = \frac{y_i\theta_i - b(\theta_i)}{\varphi} + c(y_i, \varphi)$$

Passo 2: Derivada (Regra da Cadeia)

$$\frac{\partial \ell_i}{\partial \mu_i} = \frac{\partial \ell_i}{\partial \theta_i} \cdot \frac{\partial \theta_i}{\partial \mu_i} \rightarrow \frac{y_i - b'(\theta_i)}{\varphi} \cdot \frac{\partial \theta_i}{\partial \mu_i}$$

Passo 3: Substituindo propriedades

Como $b'(\theta_i) = \mu_i$ e $V(\mu_i) = \partial \mu_i / \partial \theta_i$:

Passo 4: Gradiente Final

$$\frac{\partial \ell}{\partial \mu_i} = \frac{y_i - \mu_i}{\varphi \cdot V(\mu_i)}$$

Igualando a zero para encontrar o ponto máximo:

$$\hat{\mu}_i = y_i$$

(A 2ª derivada negativa garante que é um ponto de máximo).

Gemini Notebook

Teste de Hipóteses com o Desvio

Estrutura do Teste

Hipóteses

H_0: O modelo postulado (com p parâmetros) é adequado.

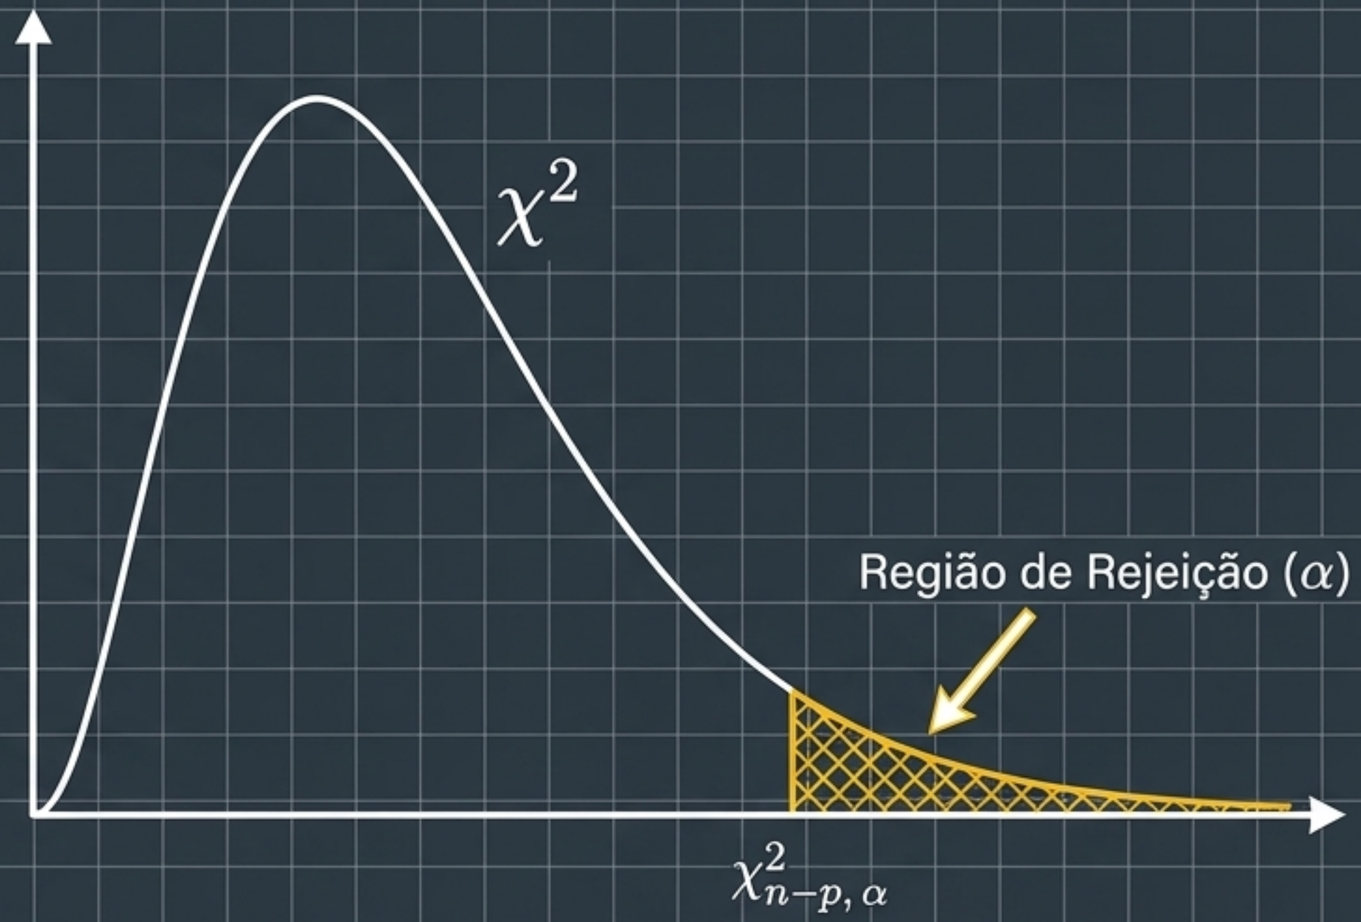
H_1: O modelo saturado é necessário (mau ajuste do postulado).

Nota de Distribuição

Assumindo $D^* \sim \chi^2_{n-p}$

Regra de Decisão

Se $D^* > \chi^2_{n-p,\,\alpha}$, rejeitamos H_0.



Um desvio pequeno indica que o modelo com p parâmetros captura quase tanta informação quanto o modelo superparametrizado. Desvio grande = mau ajuste.

Gemini Notebook

Estudo de Caso 1: Modelo Normal

Configuração da Família Exponencial

$$\theta_i = \mu_i$$

$$b(\theta_i) = \frac{\theta_i^2}{2}$$

Substituindo na diferença de verossimilhanças, os termos de y_i^2 se cancelam perfeitamente na álgebra.

Resultado

Deviance (Não Escalonado):

$$D = \sum_{i=1}^{n} (y_i - \hat{\mu}_i)^2$$

Sobre a Distribuição: $D^* = D/\sigma^2$. Como σ^2 é geralmente desconhecido, ele é estimado pela variância amostral (S^2). O Deviance D equivale à Soma de Quadrados dos Resíduos.

Gemini Notebook

Estudo de Caso 2: Modelo Poisson

Configuração da Família Exponencial

Modelo Proposto

$$\theta_i = \log(\mu_i)$$
$$b(\theta_i) = \mu_i$$

Modelo Saturado

$$\theta_i = \log(y_i)$$
$$b(\theta_i) = y_i$$

Resultado Final

Substituindo e agrupando as propriedades dos logaritmos ($y_i \log(y_i) - y_i \log(\hat{\mu}_i)$):

Deviance (Não Escalonado):

$$D = 2\sum_{i=1}^{n}\left[y_i \log\left(\frac{y_i}{\hat{\mu}_i}\right) + (\hat{\mu}_i - y_i)\right]$$

Fidelidade à resposta de contagem, incluindo a penalização natural pelas diferenças lineares $(\hat{\mu}_i - y_i)$.

Gemini Notebook

Síntese de Parâmetros MLG (Reference Matrix)

Modelo	Ligação Canônica $(\theta_i = \eta_i)$	Variância $V(\mu)$	Deviance D
Normal	Identidade: μ	1	$\sum (y_i - \hat{\mu}_i)^2$
Poisson	Log: $\log(\mu)$	μ	$2\sum \left[y_i \log \frac{y_i}{\hat{\mu}_i} + (\hat{\mu}_i - y_i) \right]$
Bernoulli	Logit: $\log\left(\frac{\mu}{1-\mu}\right)$	$\mu(1-\mu)$	$\frac{\text{Fórmula de entropia cruzada}}{\text{Deviance Binomial}}$

Gemini Notebook

Transição Computacional: Optimizando os Parâmetros ($\hat{\beta}$)

Função Score (U)

Derivada primeira (Gradiente).

Fornece a direção do ajuste.
Otimiza $X^T W$ (...).

Informação Observada (Newton-Raphson)

Matriz de derivadas segundas (Hessiana).

Complexa pois depende de y_i nas derivadas secundárias.

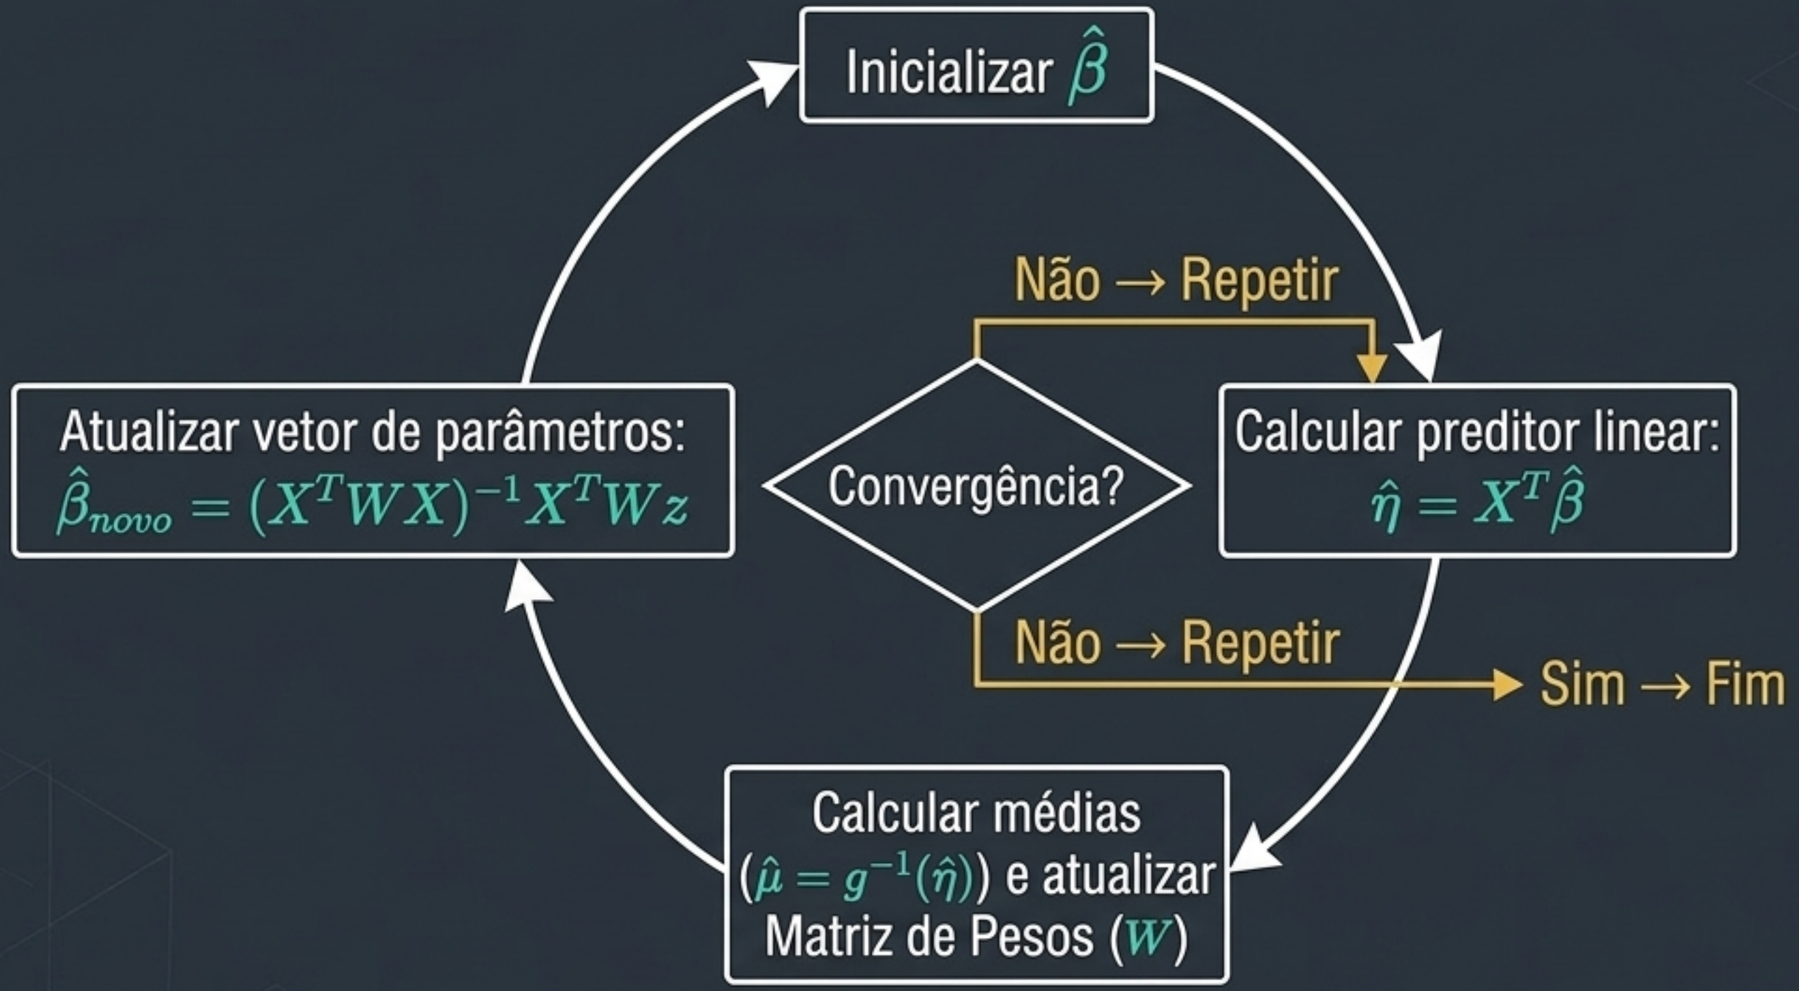
Informação Esperada (Fisher Scoring)

- O pulo do gato matemático: Ao usar o valor esperado, o termo complexo da segunda derivada zera ($\mathbb{E}[y_i - \mu_i] = 0$).
- A matriz simplifica drasticamente para:

$$X^T W X$$

Gemini Notebook

O Algoritmo IRLS (Mínimos Quadrados Reponderados Iterativamente)



Synthesis: Este é o motor sob o capô de pacotes estatísticos (R, Python). Ele generaliza mínimos quadrados usando pesos variáveis (W).

Gemini Notebook

Prática em Python: statsmodels.api

```
import statsmodels.api as sm

# Instanciando MLG Poisson com ligação Log
model = sm.GLM(Y, X, family=sm.families.Poisson(
                link=sm.families.links.log()))

result = model.fit()
```

Inicia a estrutura base.

Define $V(\mu)$ e a função de log-verossimilhança.

Define a função de ligação $g(\mu) = \eta$.

Dispara automaticamente o loop IRLS (Slide 11) para encontrar os $\hat{\beta}$.

Gemini Notebook

Fechando o Ciclo: Do Software à Realidade

O Software Devolve

O vetor $\hat{\beta}$ (ex: coeficientes do modelo de crédito).

O Preditor Linear

Calculamos o score por indivíduo:

$$\hat{\eta}_i = X_i^T \hat{\beta}$$

A Inversa da Ligação

Transformamos de volta para a escala original (ex: Logit para Probabilidade):

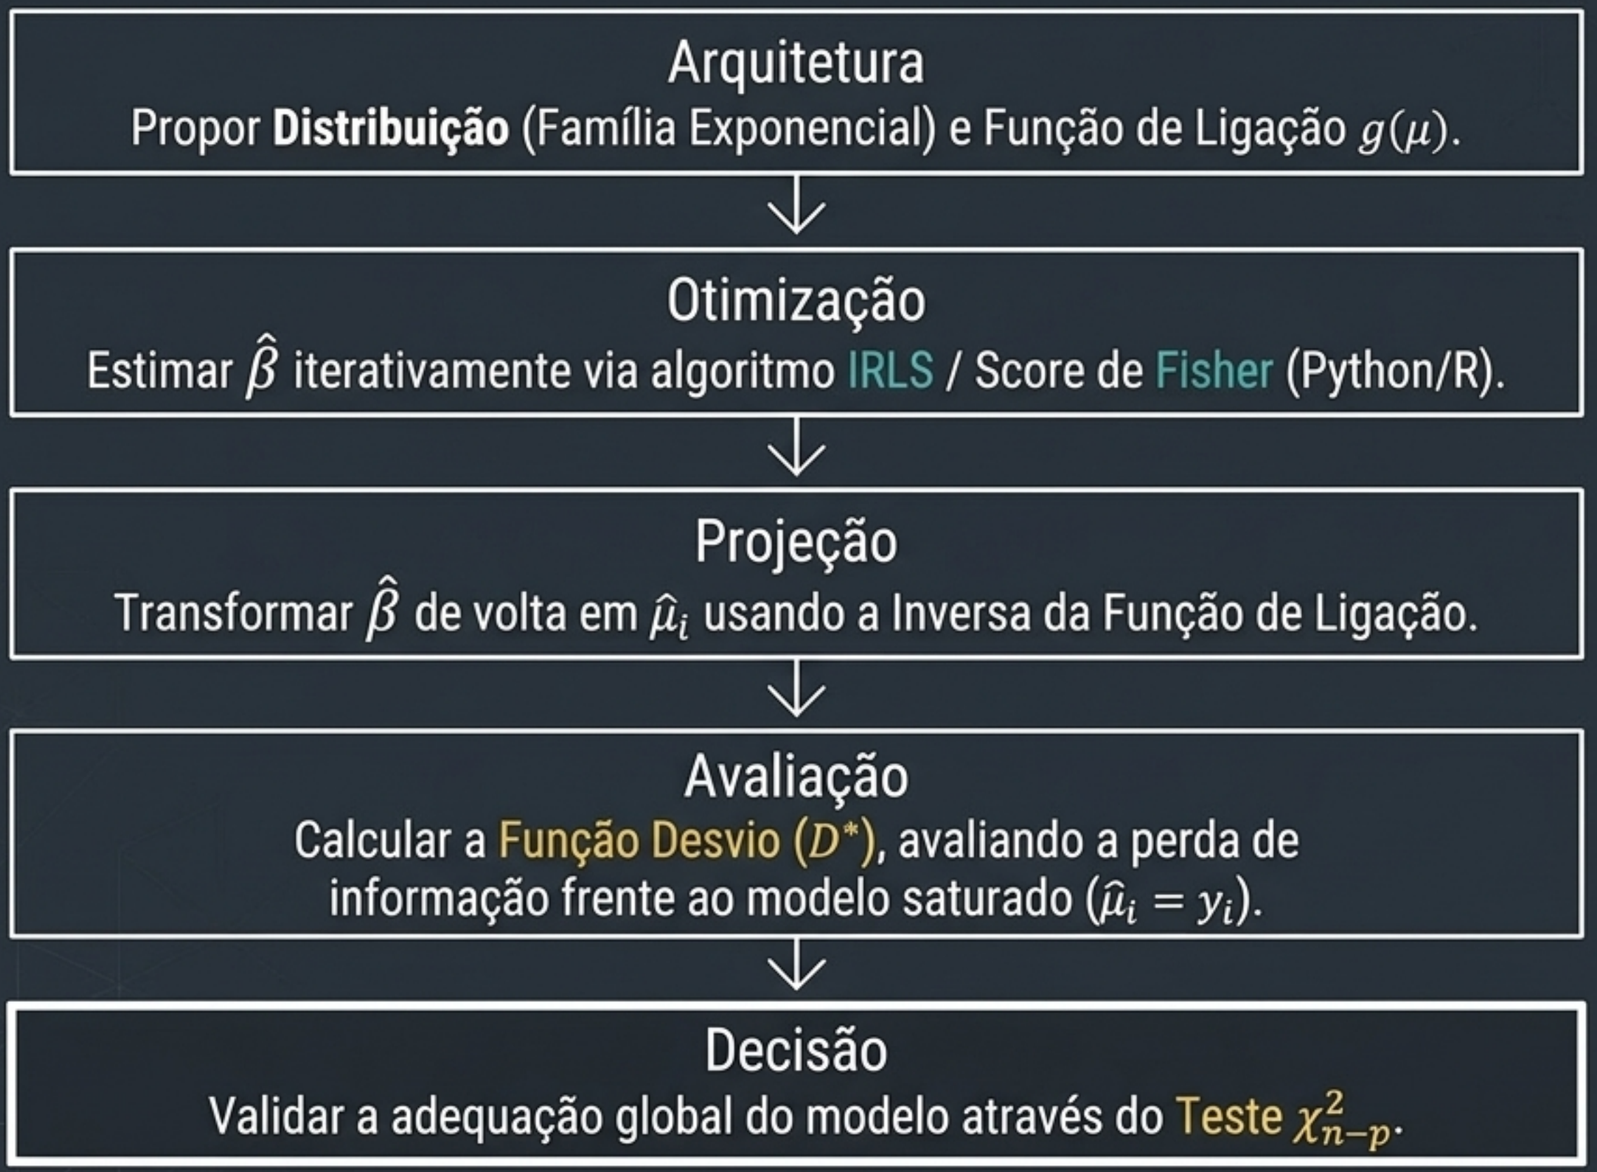
$$\hat{\mu}_i = \frac{1}{1 + \exp(-X_i^T \hat{\beta})}$$

Cálculo Final.

É com este $\hat{\mu}_i$ finalizado que calculamos o Desvio D^* (Slide 4) e avaliamos se o modelo de fato presta!

Gemini Notebook

O Fluxo Definitivo de Modelagem em MLGs



Gemini Notebook