Diagnóstico em Modelos Lineares Generalizados

A Lupa da Função Desvio: Proporções e Contagens.

GUIA VISUAL DE ESTUDO: TEORIA, DIAGNÓSTICO E APLICAÇÃO

Gemini Notebook

Arquitetura da Solução Analítica



A Mecânica

- O que é o Desvio?
- Espectro de Modelos
- O Caso Base (Normal)



Proporções

- MLGs para Bernoulli / Binomial
- A Função Logito
- Risco de Inadimplência



Contagens

- MLGs para Poisson
- O Problema da Sobredispersão
- A Solução Binomial Negativa

Gemini Notebook

A Dissecação da Função Desvio (D)

Uma medida de distância entre o modelo perfeito e o modelo proposto.

Log-verossimilhança do Modelo Saturado.
O modelo perfeito. Máxima informação possível.
Estima um parâmetro μ_i para cada observação y_i.

$$D = 2\left[l(y;y) - l(\hat{\mu};y)\right]$$

Log-verossimilhança do Modelo Ajustado.
O modelo em teste. Simplifica a realidade usando *p* parâmetros (β) para estimar $\hat{\mu}_i$.

Quanto maior a diferença entre eles, maior o Desvio.
Se D for muito grande, rejeitamos o modelo ajustado.

Gemini Notebook

A Hierarquia da Informação

O espectro de ajuste e o teste de razão de verossimilhanças.

Modelo Saturado

- Parâmetros: n (Um por observação)
- Informação: Máxima log-verossimilhança
- Métrica: Desvio zero

Modelo Ajustado (Proposto)

- Parâmetros: p (Preditoras)
- Informação: Capturada pelas covariáveis
- Métrica: Desvio Ajustado

Modelo Nulo

- Parâmetros: 1 (Apenas intercepto)
- Informação: Mínima log-verossimilhança
- Métrica: Desvio Nulo

Redução do Desvio

A diferença entre o Desvio Nulo e o Ajustado mede o ganho de informação trazido pelas preditoras. Avaliado via distribuição χ^2.

Gemini Notebook

O Caso Base: Distribuição Normal

Sob ligação identidade, o desvio reduz-se à clássica Soma de Quadrados.

Premissas

- **Distribuição:** $Y \sim N(\mu, \sigma^2)$
- **Ligação Canônica:** Identidade $(\mu = X\beta)$
- **Parâmetro de Dispersão:** σ^2 conhecido

Dedução Matemática

1. O Desvio não escalonado isola a diferença:

$$D = \sum (y_i - \hat{\mu}_i)^2$$

2. Que é exatamente a Soma de Quadrados dos Resíduos (SQR).
3. O Desvio escalonado:

$$\frac{D}{\sigma^2} \sim \chi^2_{n-p}$$ (Graus de liberdade)

Atenção: Se σ^2 é estimado via quadrado médio do resíduo, $D/\hat{\sigma}^2 = n-p$ (uma constante). A distribuição exata exige σ^2 conhecido ou uso de quantis sugeridos pela literatura.

Gemini Notebook

Anatomia do Modelo de Proporção

Respostas binárias (Bernoulli) e a Função de Ligação Logito.

Variável Resposta: $Y \in \{0,1\}$

Preditor Linear: $\eta_i = X\beta$

Transformação Matemática

Função de Ligação (Logito)

$$\eta_i = \log\left(\frac{\mu_i}{1-\mu_i}\right)$$

Mapeia probabilidades (0,1) para os reais $(-\infty, \infty)$.

Função Inversa (Expit)

$$\hat{\mu}_i = \frac{1}{1+e^{-\eta_i}}$$

Usada para recuperar as probabilidades estimadas a partir dos coeficientes β.

Gemini Notebook

A Função Desvio na Prática: Bernoulli

Deduzindo a perda de informação para respostas binárias.

Para $Y_i \sim \text{Bernoulli}(\mu_i)$, a função desvio é:

$$D = 2\sum\left[y_i \log\left(\frac{y_i}{\hat{\mu}_i}\right) + (1-y_i)\log\left(\frac{1-y_i}{1-\hat{\mu}_i}\right)\right]$$



A Convenção Matemática Crucial

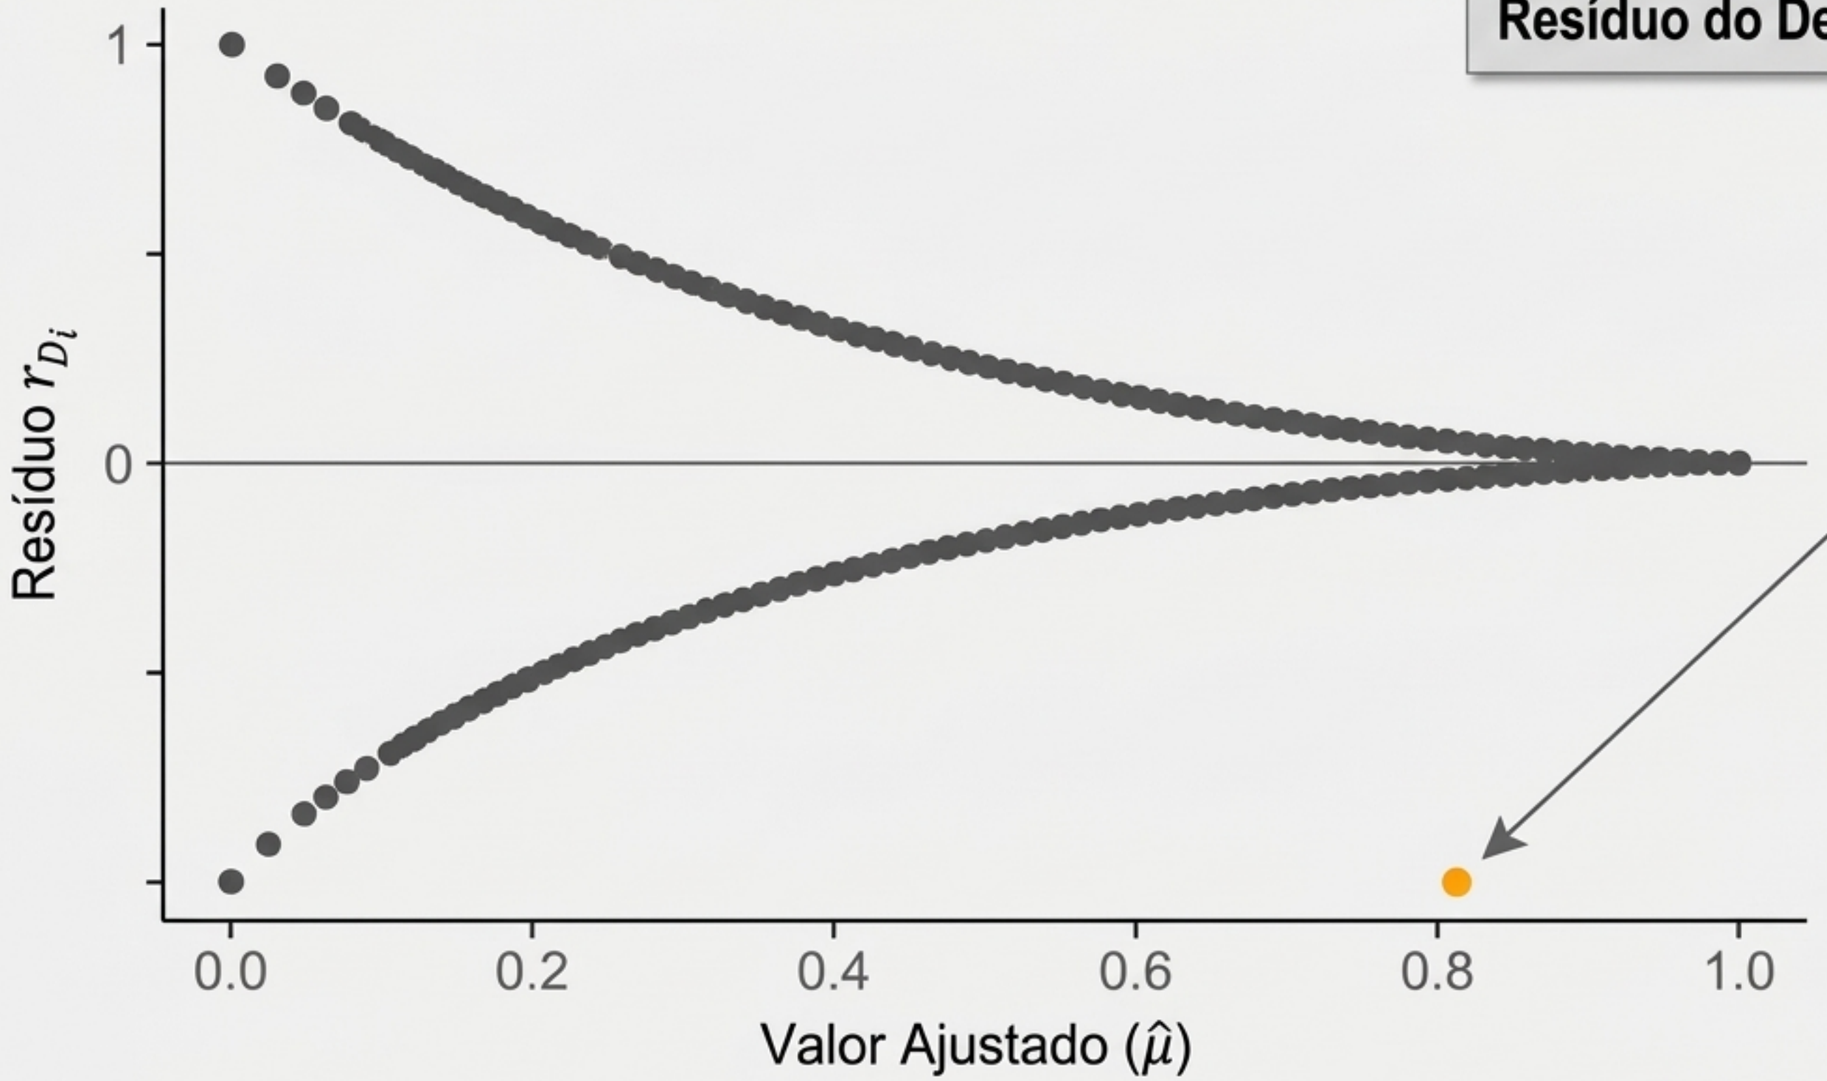
Como y_i assume apenas 0 ou 1, na dedução encontramos o termo 0 log(0). Pela regra de limites e por convenção em MLGs, assumimos 0 log(0) = 0. Isso zera a log-verossimilhança do modelo saturado neste caso específico, permitindo o cálculo do desvio.

Gemini Notebook

Diagnóstico pelo Componente do Desvio

Lendo o gráfico de Resíduos vs. Valores Ajustados ($\hat{\mu}$).

Resíduo do Desvio: $r_{D_i} = \text{sgn}(y_i - \hat{\mu}_i)\sqrt{d_i}$



Alerta de Diagnóstico

O modelo atribuiu alta probabilidade (81%) a um evento que na realidade não ocorreu (Y=0). Resulta no maior componente de resíduo em módulo.

Gemini Notebook

Caso de Aplicação: Risco de Inadimplência

Traduzindo parâmetros β em métricas de negócio.

Estrutura do Banco de Dados

- **Variável Resposta (Y):** Inadimplência (1 = Sim, 0 = Não)
- **Preditoras Chave:** Idade, Salário, Saldo Devedor

```
sm.GLM(...,
family=sm.families.Binomial(
link=sm.families.links.logit))
```

Razão de Chances (Odds Ratio)

A interpretação de impacto na regressão logística não é linear.

$$\text{Razão de Chances} = e^{\hat{\beta}}$$

- **Exemplo da aula:** Se $\hat{\beta}_{\text{salário}} = -0.0011$, então $e^{-0.0011} \approx 0.9989$.
- **Interpretação Analítica:** A cada unidade monetária de aumento no salário, a chance de o cliente entrar em inadimplência sofre uma redução de ~0.1%.

Gemini Notebook

Modelando Contagens: Distribuição Poisson

A Função Desvio para variáveis de resposta discretas $Y \in \{0, 1, 2, \ldots\}$.

Desenvolvido a partir das log-verossimilhanças, o Desvio para Poisson assume a forma:

$$D = 2\sum\left[y_i \log\frac{y_i}{\hat{\mu}_i} - (y_i - \hat{\mu}_i)\right]$$

Mecânica do Modelo

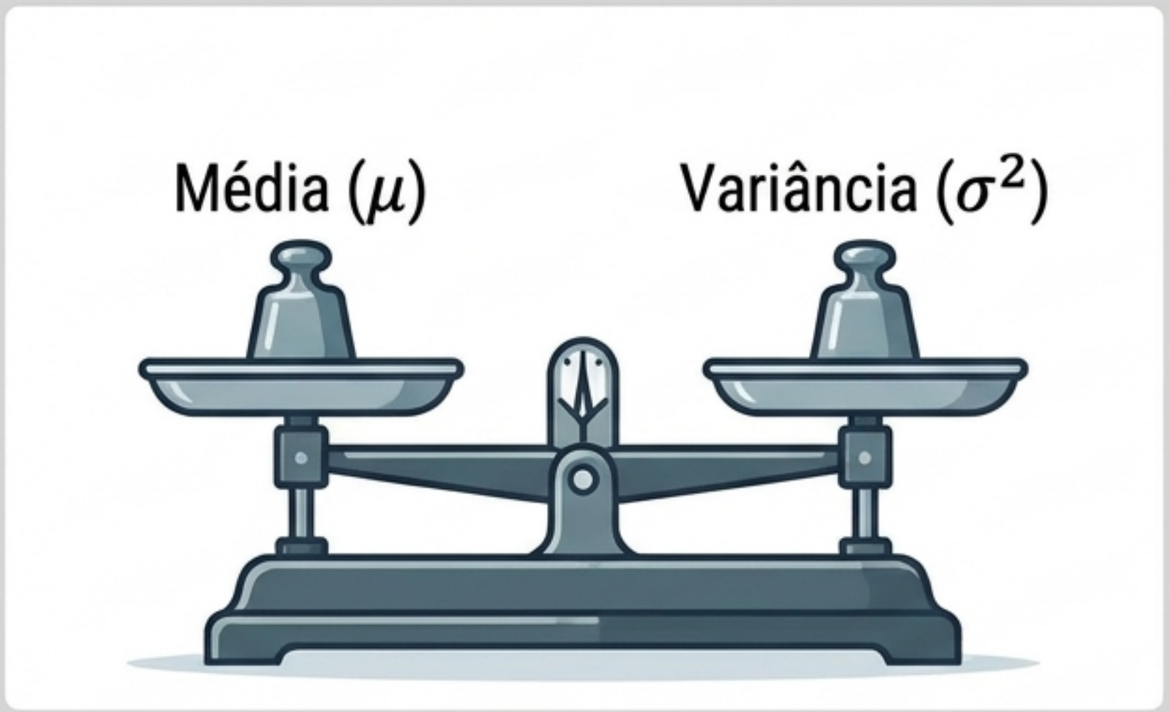
- Ligação Canônica: Função Log ($\log(\mu) = \boldsymbol{X\beta}$).
- Função Inversa: Exponencial ($\hat{\mu} = e^{X\beta}$).

- ⚠ **Premissa Central:** A Média é estritamente igual à Variância ($\mu = \sigma^2$). O modelo assume dispersão perfeitamente controlada.

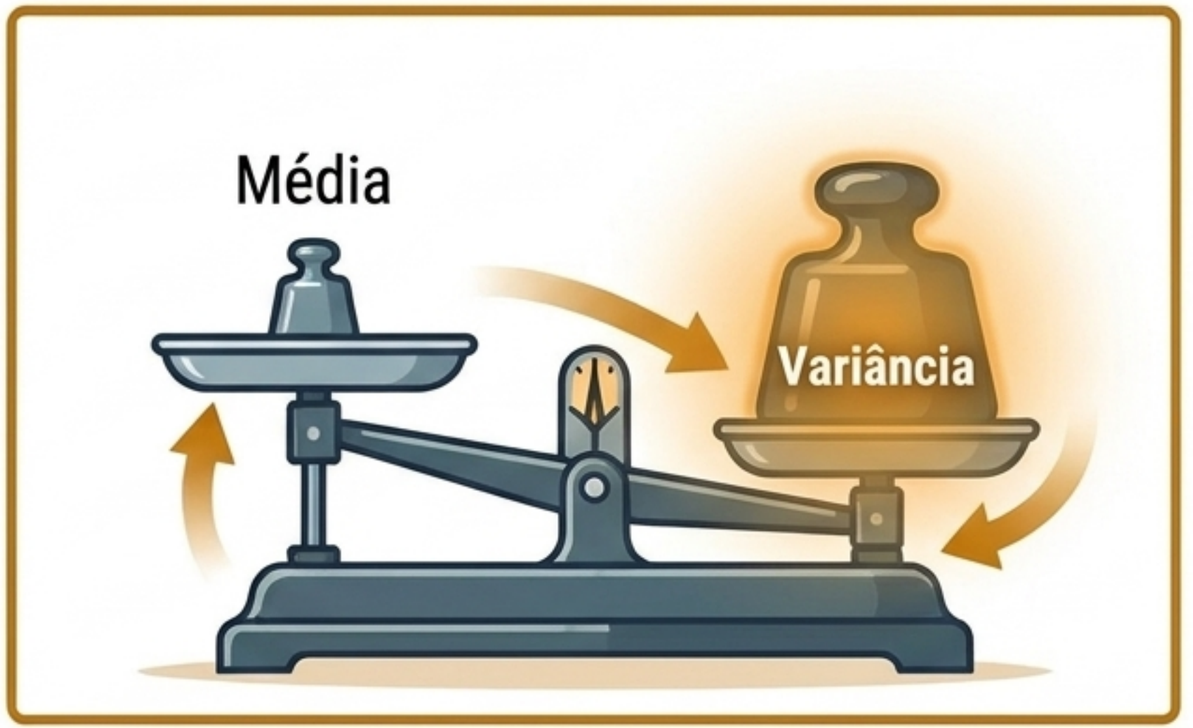
Gemini Notebook

O Ponto Cego: Sobredispersão

Quando o modelo Poisson falha silenciosamente diante da realidade dos dados.



A **Premissa Poisson** ($\mu = \sigma^2$). O modelo assume que a variabilidade cresce exatamente na mesma proporção que a média esperada.



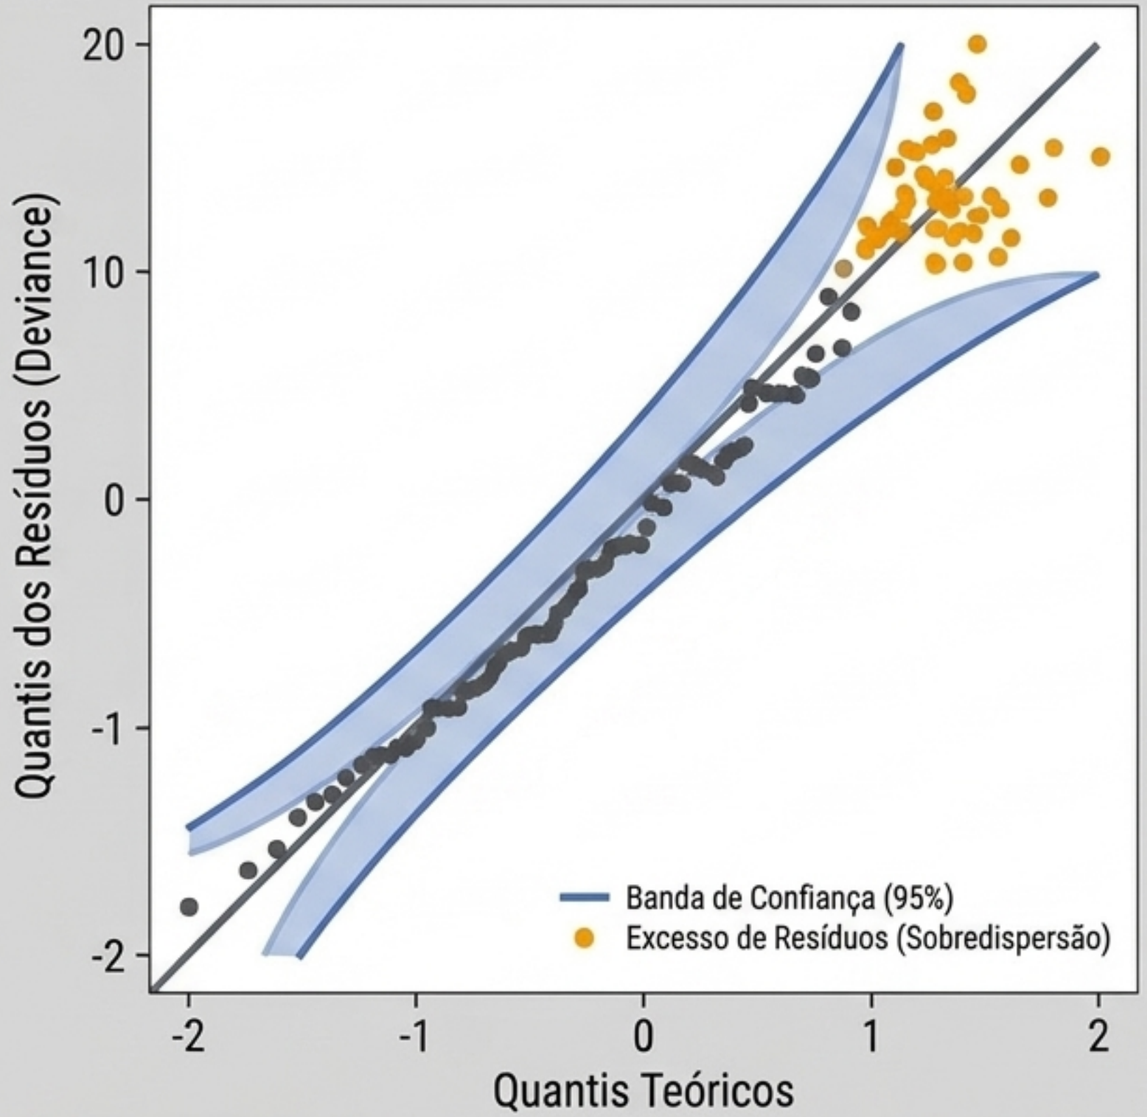
A **Realidade dos Dados (Variância > Média)**. Caudas pesadas ou excesso de zeros. A variabilidade observada destrói a premissa.

Impacto Crítico: Na presença de sobredispersão, o desvio do modelo Poisson é artificialmente inflado, resultando em p-valores falsamente pequenos e falsos positivos.

Gemini Notebook

Diagnóstico Visual: Gráfico de Envelope

Usando bandas de confiança simuladas para testar a adequação estrutural.



Sintoma Visual de Sobredispersão

Os resíduos (componentes do desvio) ultrapassam repetidamente os limites teóricos do envelope simulado.

O gráfico revela que o modelo Poisson padrão não tem capacidade estrutural para capturar a variabilidade real (extrema) dos dados. Uma **correção de distribuição é obrigatória.**

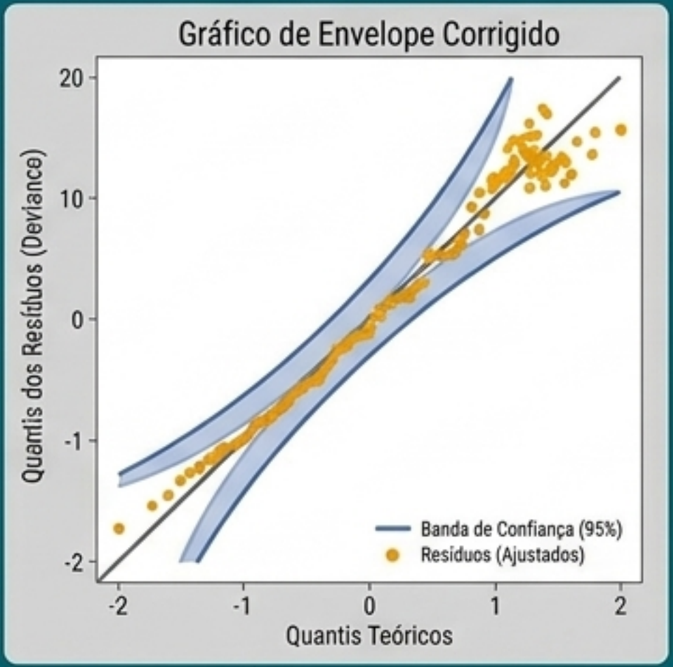
Gemini Notebook

A Solução Estrutural: Binomial Negativa

Absorvendo a variância extra e aplicando em dados de logística.

Expansão da Variância

- **Novo Parâmetro**: Introduz α (parâmetro de dispersão).
- **Nova Variância**: $\sigma^2 = \mu + \alpha\mu^2$ (Permite Variância > Média).



Caso de Aplicação: Entregas

Modelagem de Pedidos

- **Dataset**: 100 registros de entregas.
- **Variável Resposta (Y)**: Número de produtos no pedido (Contagem discreta).
- **Preditoras**: Categoria do produto, Dia da semana, Promoção.

```
sm.GLM(y, X, family=sm.families.NegativeBinomial())
```

***Nota Prática**: Em variáveis categóricas (como 'Categoria'), se apenas um nível for significativo, mantemos a variável inteira no modelo via dummy variables.*

Gemini Notebook

A Matriz de MLGs: Resumo Diagnóstico

O guia de referência rápida arquitetural para os três cenários base.

Distribuição	Resposta & Ligação	Expressão do Desvio (D)	Foco de Diagnóstico
Normal (Base)	Contínua $(-\infty, \infty)$. Identidade $(\mu = \eta)$	Soma de Quadrados dos Resíduos (SQR)	Normalidade dos resíduos, homocedasticidade (σ^2 constante).
Bernoulli (Proporção)	Binária (0 ou 1). Logito $\left(\log\left(\frac{\mu}{1-\mu}\right)\right)$	$2\sum\left[y_i \log\left(\frac{y_i}{\hat{\mu}_i}\right) + (1-y_i)\log\left(\frac{1-y_i}{1-\hat{\mu}_i}\right)\right]$	Pontos de alavanca, resíduos de predições fortemente divergentes do evento real.
Poisson (Contagem)	Inteiros (0, 1, 2...). Log $(\log(\mu))$	$2\sum\left[y_i \log\left(\frac{y_i}{\hat{\mu}_i}\right) - (y_i - \hat{\mu}_i)\right]$	Sobredispersão (vazamento nos limites do Gráfico de Envelope).

Gemini Notebook

Próximos Passos na Arquitetura Analítica

Tópicos de estudo para a próxima fase e o toolkit prático em Python.

Fronteira Teórica

1. **Inferência e Testes:** Aprofundamento no Teste Score, Teste de Wald e Teste Score, Teste de Wald e Razão de Verossimilhanças.
2. **Balanceamento de Dados:** Estratégias para bases severamente desbalanceadas (ex: Inadimplência rara).
3. **Novas Funções de Ligação:** Explorar Probit e C-Log-Log (Complementary Log-Log) para modelagem binomial alternativa.

Toolkit Python (Statsmodels)

- **`sm.GLM(y, X, family=...)`** : Inicializa a classe base.
- **`.fit()`** : Executa a estimação dos parâmetros (β).
- **`.fittedvalues`** : Retorna as probabilidades/médias ($\hat{\mu}_i$).
- **`.resid_deviance`** : Extrai os resíduos componentes do desvio.
- **`.get_influence().hat_matrix_diag`** : Vetor para análise de pontos de alavanca (H_{ii}).

Gemini Notebook